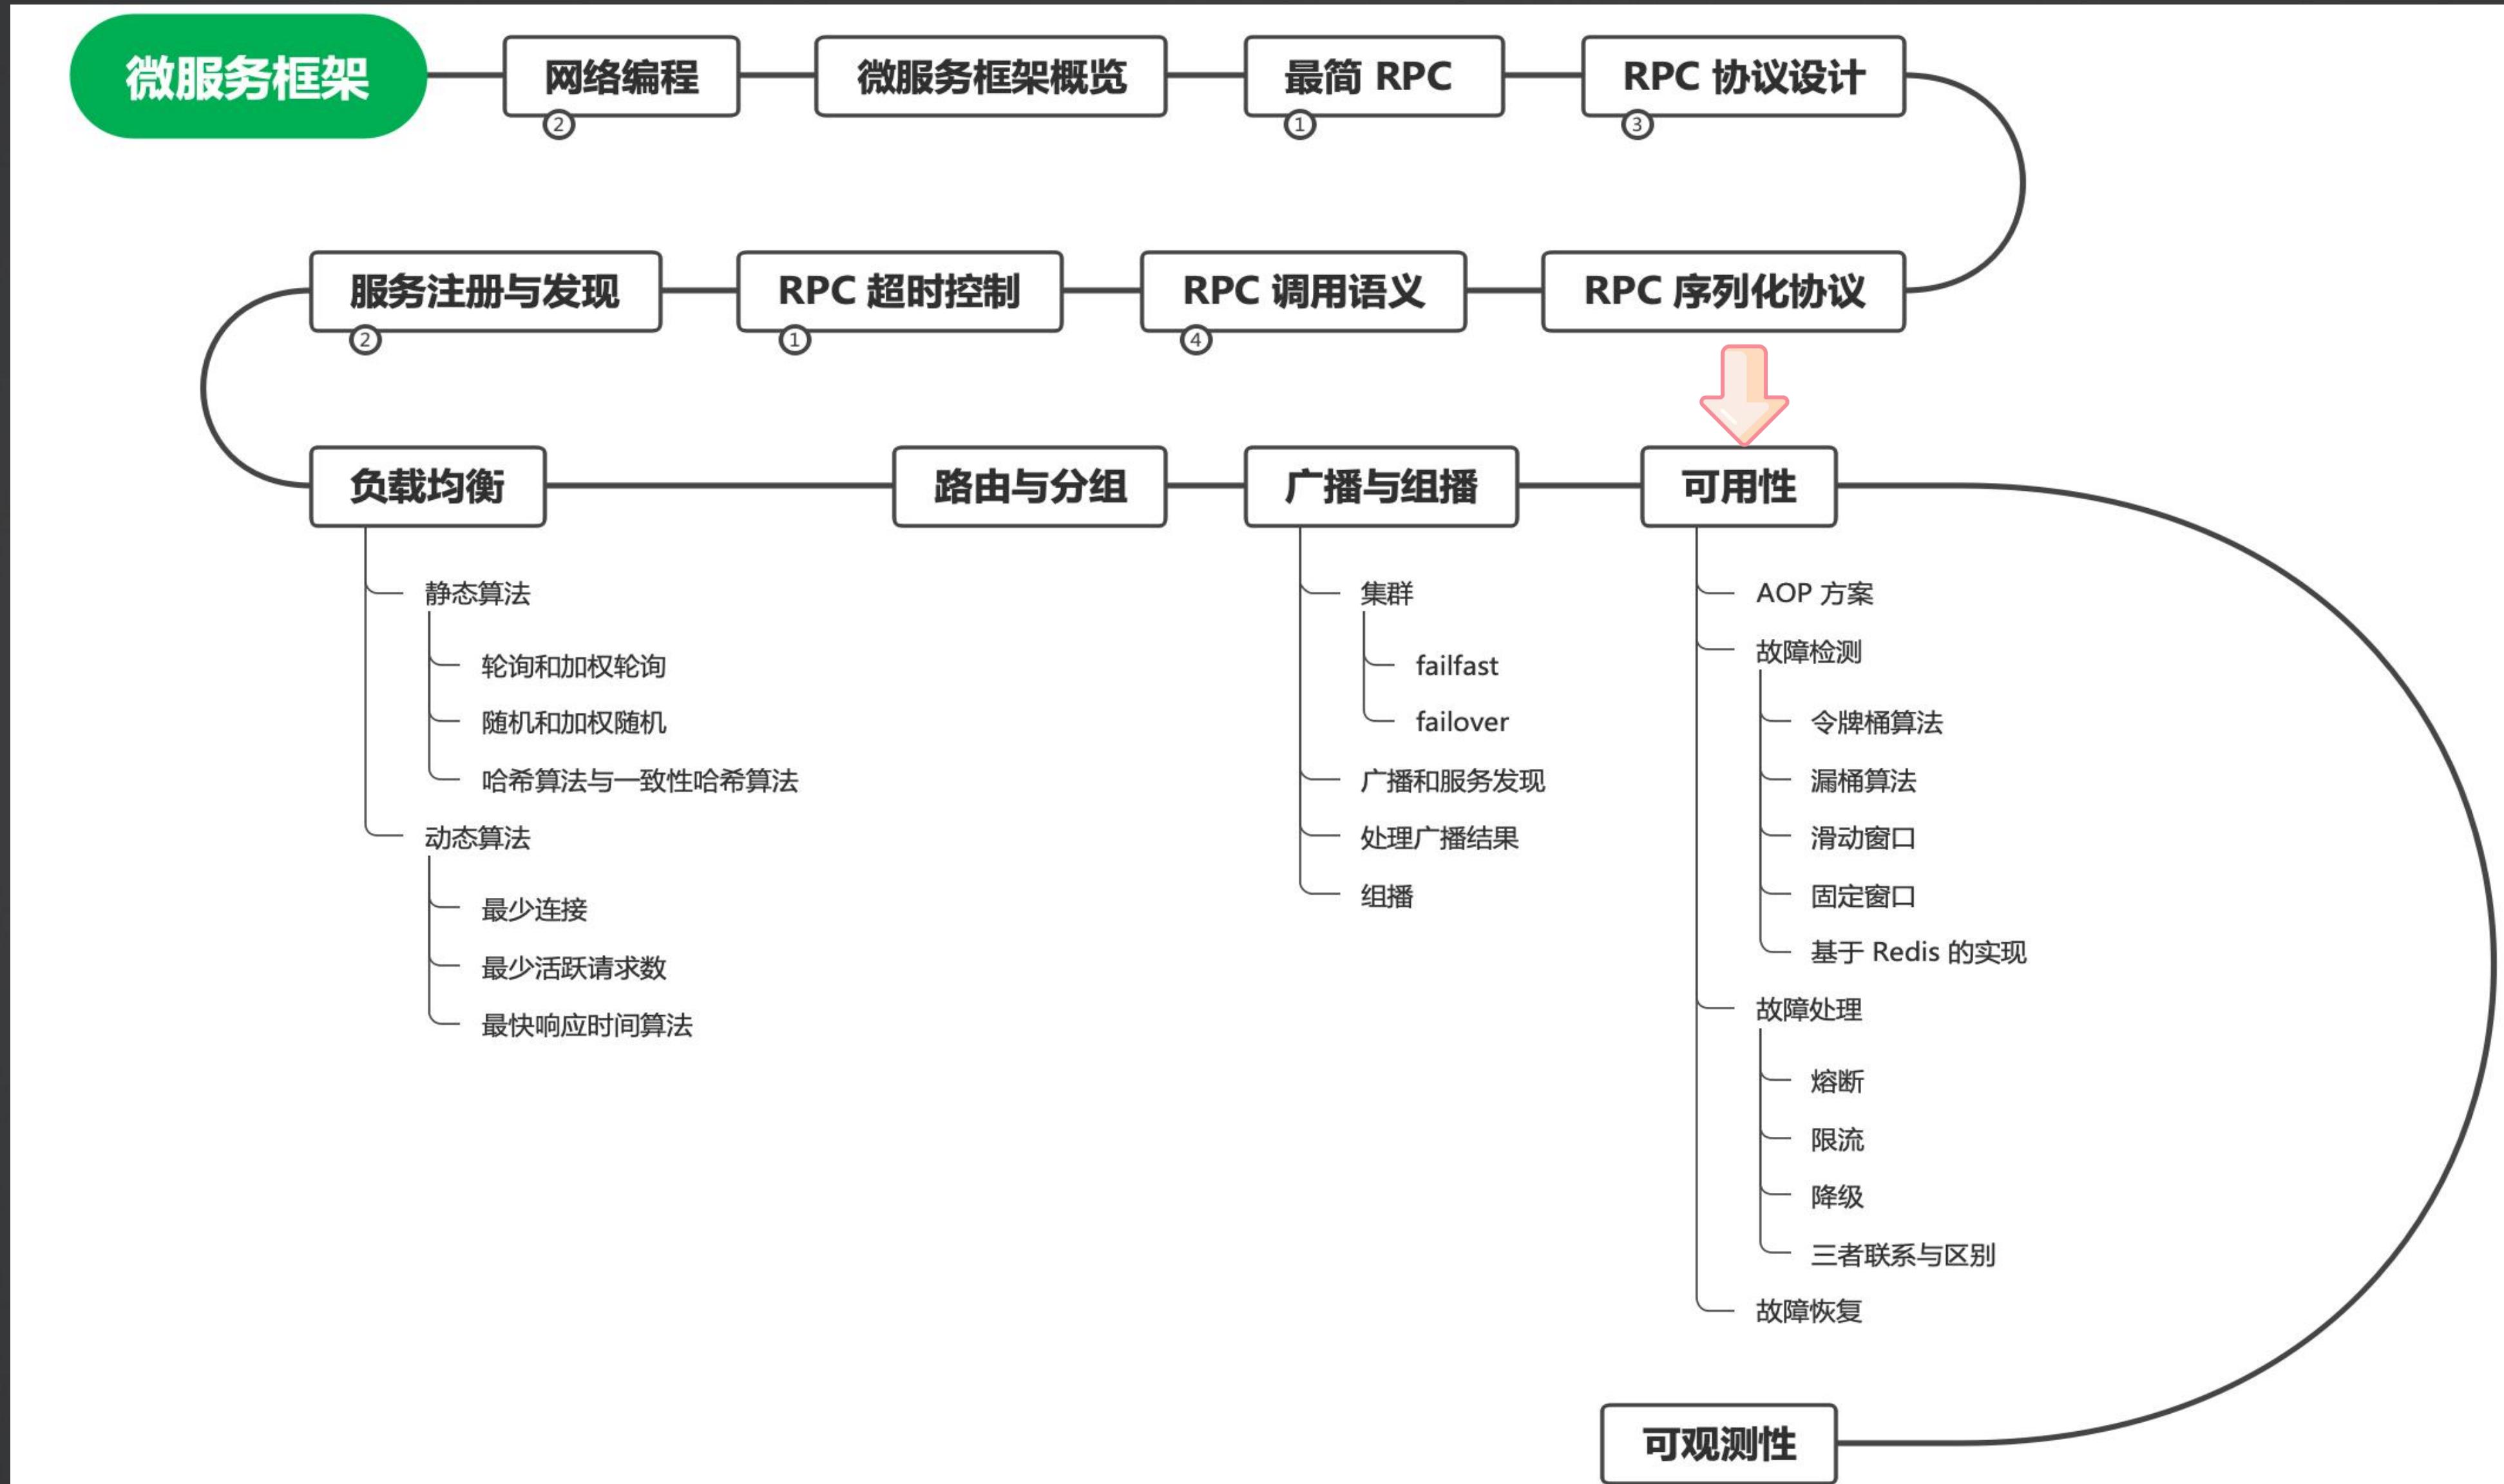


微服务框架 —— 可用性

大明



AOP 方案：Kratos

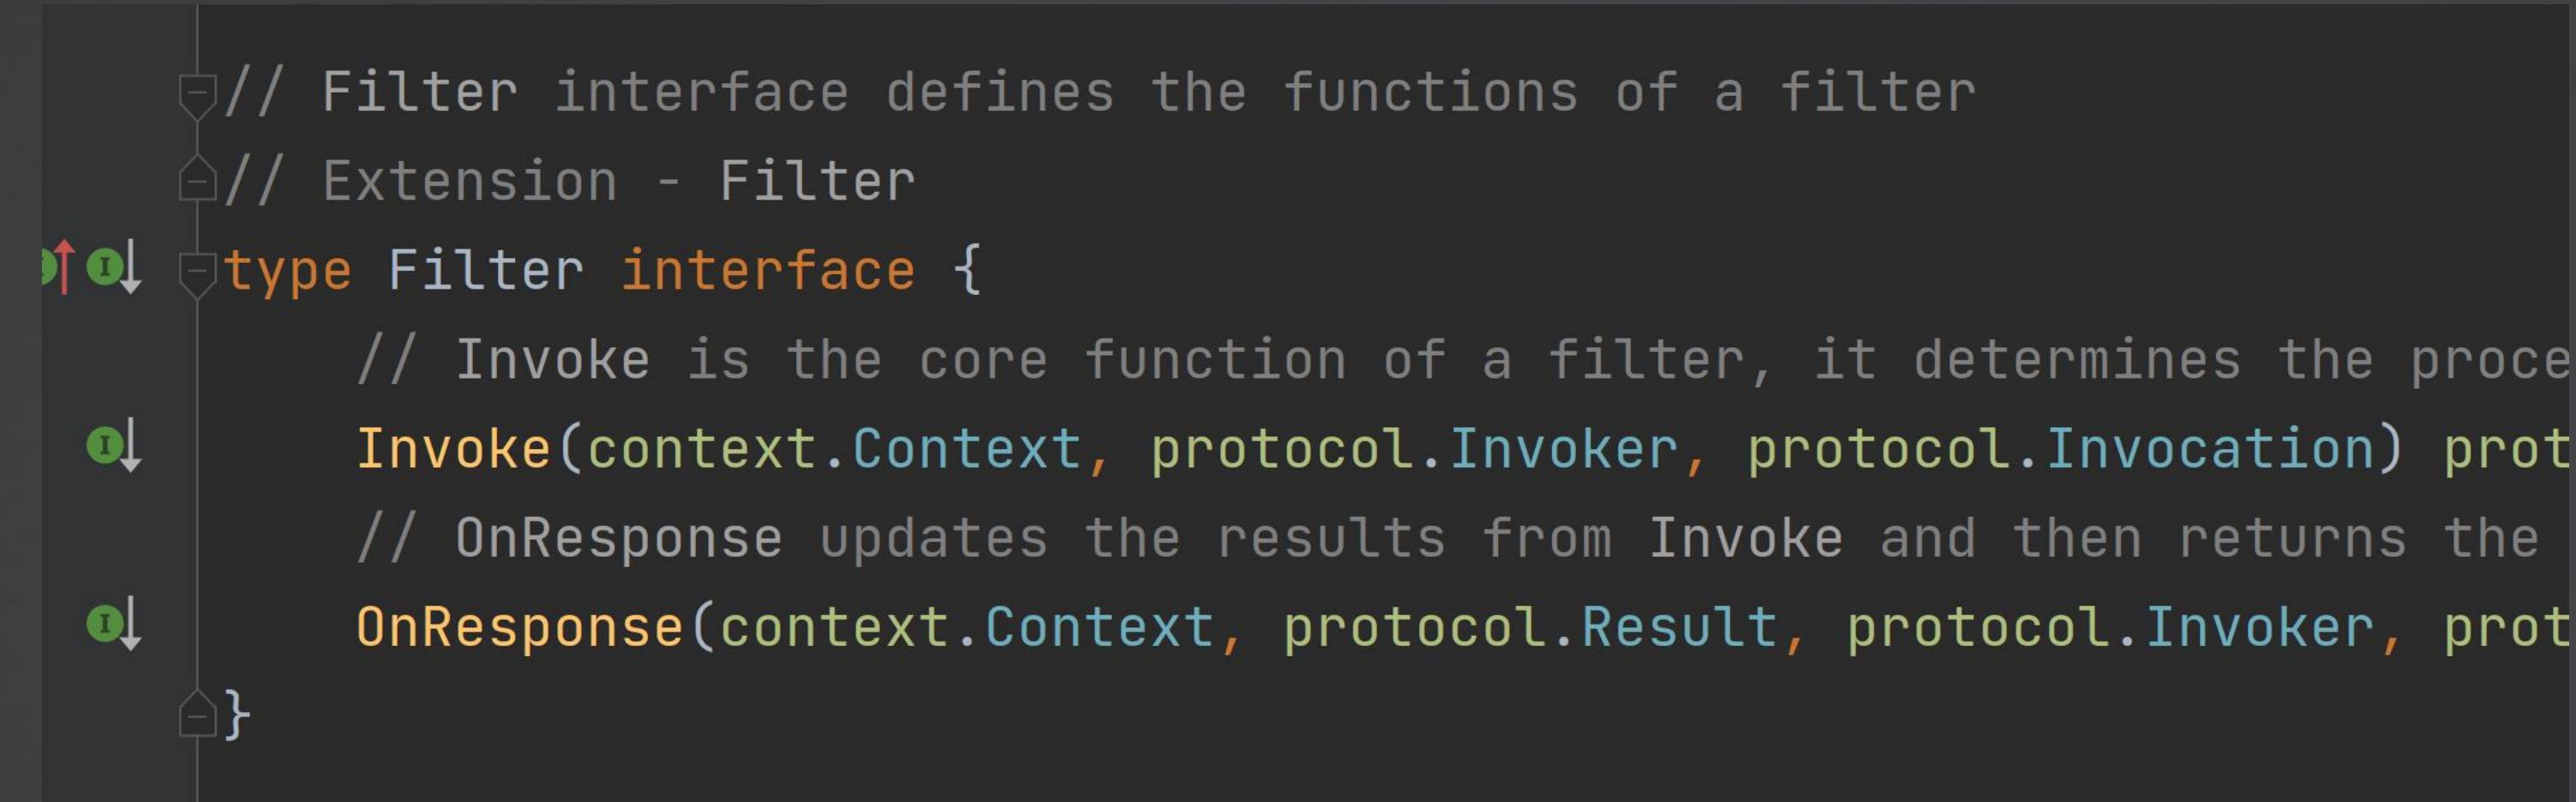
```
// Handler defines the handler invoked by Middleware.
type Handler func(ctx context.Context, req interface{}) (interface{}, error)

// Middleware is HTTP/gRPC transport middleware.
type Middleware func(next Handler) Handler

// Chain returns a Middleware that specifies the chained handler
func Chain(m ...Middleware) Middleware {
    return func(next Handler) Handler {
        for i := len(m) - 1; i >= 0; i-- {
            next = m[i](next)
        }
        return next
    }
}
```

我们在 Web 框架和 ORM 框架中都是采用类似的设计。

AOP 方案：Dubbo-go



```
// Filter interface defines the functions of a filter
// Extension - Filter
type Filter interface {
    // Invoke is the core function of a filter, it determines the process
    // of the request
    Invoke(context.Context, protocol.Invoker, protocol.Invocation) protocol.Result
    // OnResponse updates the results from Invoke and then returns the
    // response
    OnResponse(context.Context, protocol.Result, protocol.Invoker, protocol.Invocation)
}
```

The diagram shows the `Filter` interface definition. It includes two methods: `Invoke` and `OnResponse`. The `Invoke` method takes a `Context`, `Invoker`, and `Invocation` as parameters and returns a `Result`. The `OnResponse` method takes a `Context`, `Result`, `Invoker`, and `Invocation` as parameters.

Dubbo-go 的设计更加接近责任链的设计。其中它有一个回调接口 `OnResponse`，即响应返回的时候会执行这个方法。

AOP 方案：go-micro

go-micro 叫做 Wrapper，也就是认为自己是在已有功能的基础上再封装一些功能，（我猜）设计者认为它更加接近装饰器模式或者洋葱模式。

客户端 Wrapper 分成三类：

- **CallWrapper**: 最细粒度控制，针对每一次调用
- **Wrapper**: 针对客户端的 Wrapper
- **SteamWrapper**: 针对 Stream API 的 Wrapper

实际上我认为 Wrapper 和 CallWrapper 只需要保留一个就可以。通过注册过程来控制作用范围，例如我们在某个调用里面注册 Wrapper，那么只对该调用起效果。

```
// CallFunc represents the individual call func
type CallFunc func(ctx context.Context, node *registry.Node,
                     ...)

// CallWrapper is a low level wrapper for the CallFunc
type CallWrapper func(CallFunc) CallFunc

// Wrapper wraps a client and returns a client
type Wrapper func(Client) Client

// StreamWrapper wraps a Stream and returns the equivalent
type StreamWrapper func(Stream) Stream
```

AOP 方案: go-micro

服务端的 Wrapper 定义不太一样，核心就是 HandlerWrapper 和 StreamWrapper，其作用接近于客户端的 Wrapper 和 StreamWrapper。

从个人偏好上来说，我既不喜欢客户端和服务端设计不同 API 的做法，也不喜欢普通请求和 Stream 请求分别对待的做法。

个人比较喜欢 Dubbo-go 那种一致的抽象。

```
// HandlerFunc represents a single method of a handler. It's used primarily for the wrappers. What's handed to the actual method is the concrete request and response types.
type HandlerFunc func(ctx context.Context, req Request, rsp interface{}) error

// SubscriberFunc represents a single method of a subscriber. It's used primarily for the wrappers. What's handed to the actual method is the concrete publication message.
type SubscriberFunc func(ctx context.Context, msg Message) error

// HandlerWrapper wraps the HandlerFunc and returns the equivalent HandlerFunc
type HandlerWrapper func(HandlerFunc) HandlerFunc

// SubscriberWrapper wraps the SubscriberFunc and returns the equivalent SubscriberFunc
type SubscriberWrapper func(SubscriberFunc) SubscriberFunc

// StreamWrapper wraps a Stream interface and returns the equivalent Stream
// Because streams exist for the lifetime of a method invocation they can be wrapped
// is a convenient way to wrap a Stream as its in use for trace, monitoring, metrics, etc.
type StreamWrapper func(Stream) Stream
```

可用性

在微服务框架中，可用性是和服务治理最密切相关的主题：

- 熔断
- 限流
- 降级
- 重试：这个主题我们已经在 cluster 里面接触过了
- 超时控制：我们在 RPC 设计的时候也接触过了

可用性：Kratos

限流接口，会返回一个回调，这个回调会在请求结束之后执行，也就是 DoneFunc。

```
// Limiter is a rate limiter.  
type Limiter interface {  
    Allow() (DoneFunc, error)  
}  
  
}  
  
return func(handler middleware.Handler) middleware.Handler {  
    return func(ctx context.Context, req interface{}) (reply int,  
        done, e := options.limiter.Allow()  
    if e != nil {  
        // rejected  
        return reply: nil, ErrLimitExceed  
    }  
    // allowed  
    reply, err = handler(ctx, req)  
    done(ratelimit.DoneInfo{Err: err})  
    return  
}
```

可用性：Kratos

熔断接口。

注意，在限流和熔断里面，其实 API 很像，都是一个 Allow 方法。

```
return func(handler middleware.Handler) middleware.Handler {
    return func(ctx context.Context, req interface{}) (interface{}, error) {
        info, _ := transport.FromServerContext(ctx)
        breaker := opt.group.Get(info.Operation()).(circuit.Breaker)
        if err := breaker.Allow(); err != nil {
            // rejected
            // NOTE: when client reject requests locally
            // continue add counter let the drop ratio low
            breaker.MarkFailed()
            return nil, ErrNotAllowed
        }
        // allowed
        reply, err := handler(ctx, req)
        if err != nil && (errors.IsInternalServerError(err) || errors.IsTemporaryFailure(err)) {
            breaker.MarkFailed()
            return nil, ErrInternalServerError
        }
        return reply, err
    }
}
```

可用性：Dubbo-go 限流

限流的核心接口是 **TpsLimiter**。

```
* The usage, for example:  
* "UserProvider":  
*   registry: "hangzhouzk"  
*   protocol : "dubbo"  
*   interface : "com.ikurento.user.UserProvider"  
*   ... # other configuration  
*   tps.limiter: "the name of limiter",  
*/  
type TpsLimiter interface {  
    // IsAllowable will check whether this invocation should  
    IsAllowable(*common.URL, protocol.Invocation) bool  
}
```

可用性：Dubbo-go 接入 Hystrix

Dubbo-go 主要依赖于 Hystrix 来做熔断。早几年的时候 Hystrix 很流行，目前来看，已经不是很流行了。

核心是利用 Hystrix 的 Do 方法，传入一个方法。这个方法要么被执行，要么被 Hystrix 触发熔断。

```
logger.Infof("Hystrix Filter using Hystrix Filter. %s", cmdName)
var result protocol.Result
_ = hystrix.Do(cmdName, func() error {
    result = invoker.Invoke(ctx, invocation)
    err := result.Error()
    if err != nil {
        result.SetError(NewHystrixFilterError(err, failByHystrix))
        for _, reg := range f.res[invocation.MethodName()] {
            if reg.MatchString(err.Error()) {
                logger.Debugf(fmt.Sprintf("[Hystrix Filter]Error in %s", invocation))
                return nil
            }
        }
    }
    return err
}, func(err error) error {
```

可用性：go-micro 限流

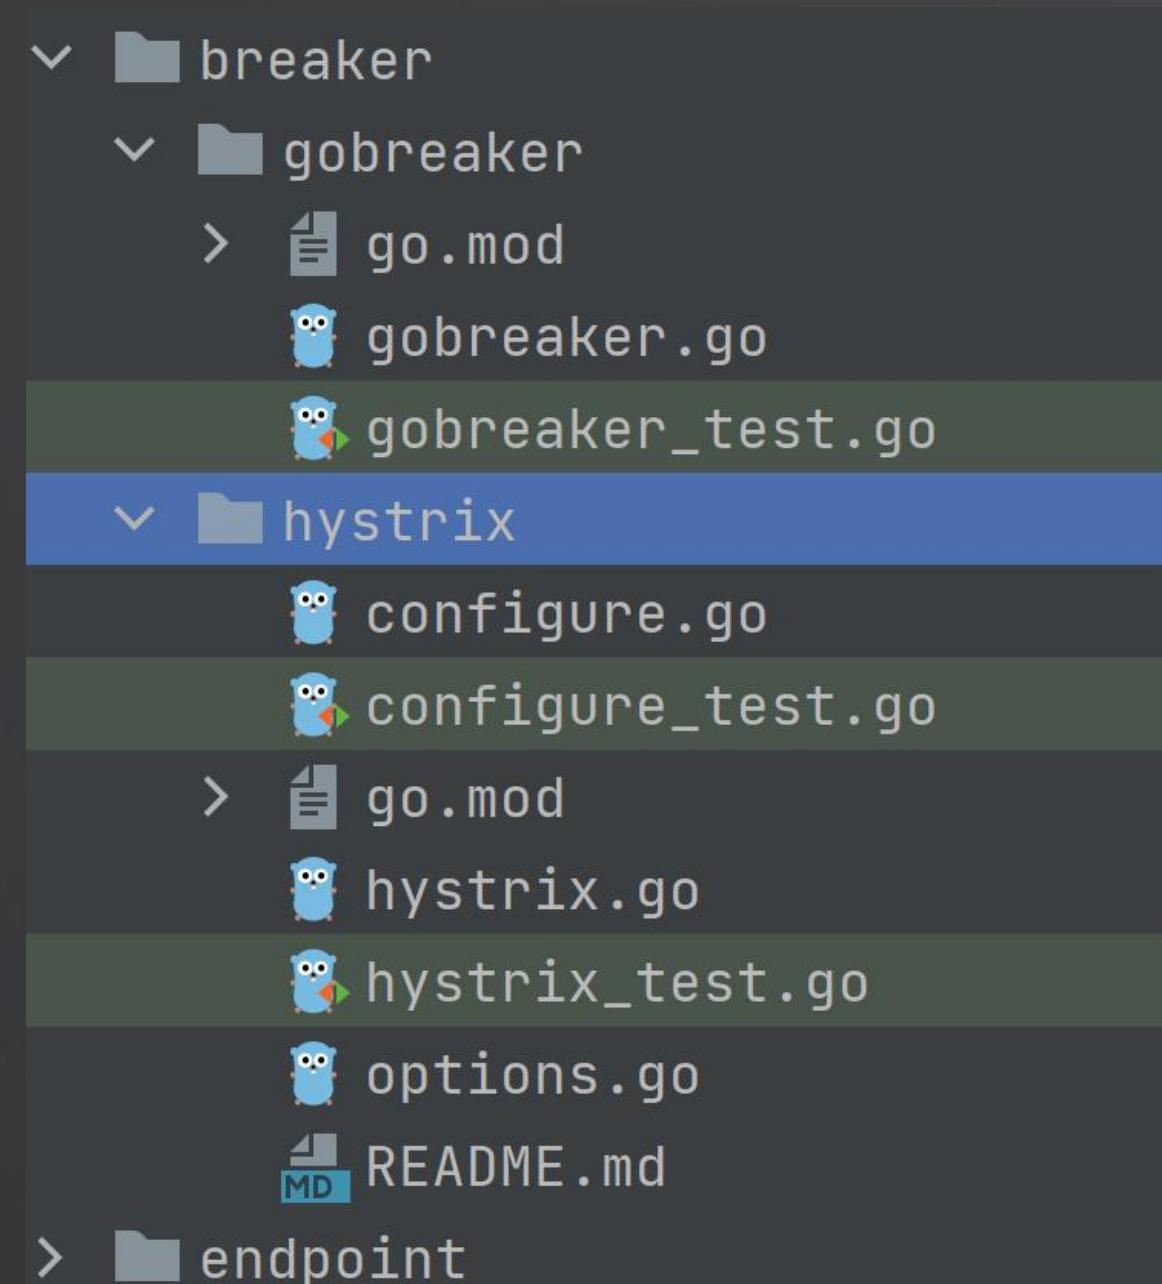
go-micro 支持客户端限流和服务端限流。

它的 plugins 仓库提供的限流利用了 github.com/juju/ratelimit 库，采用的就是令牌桶算法。

```
// Bucket represents a token bucket that fills requests.  
// Methods on Bucket may be called concurrently.  
  
type Bucket struct {  
    clock Clock  
  
    // startTime holds the moment when the bucket first started.  
    // first created and ticks began.  
    startTime time.Time  
  
    // capacity holds the overall capacity of the bucket.  
    capacity int64
```

可用性：go-micro 熔断

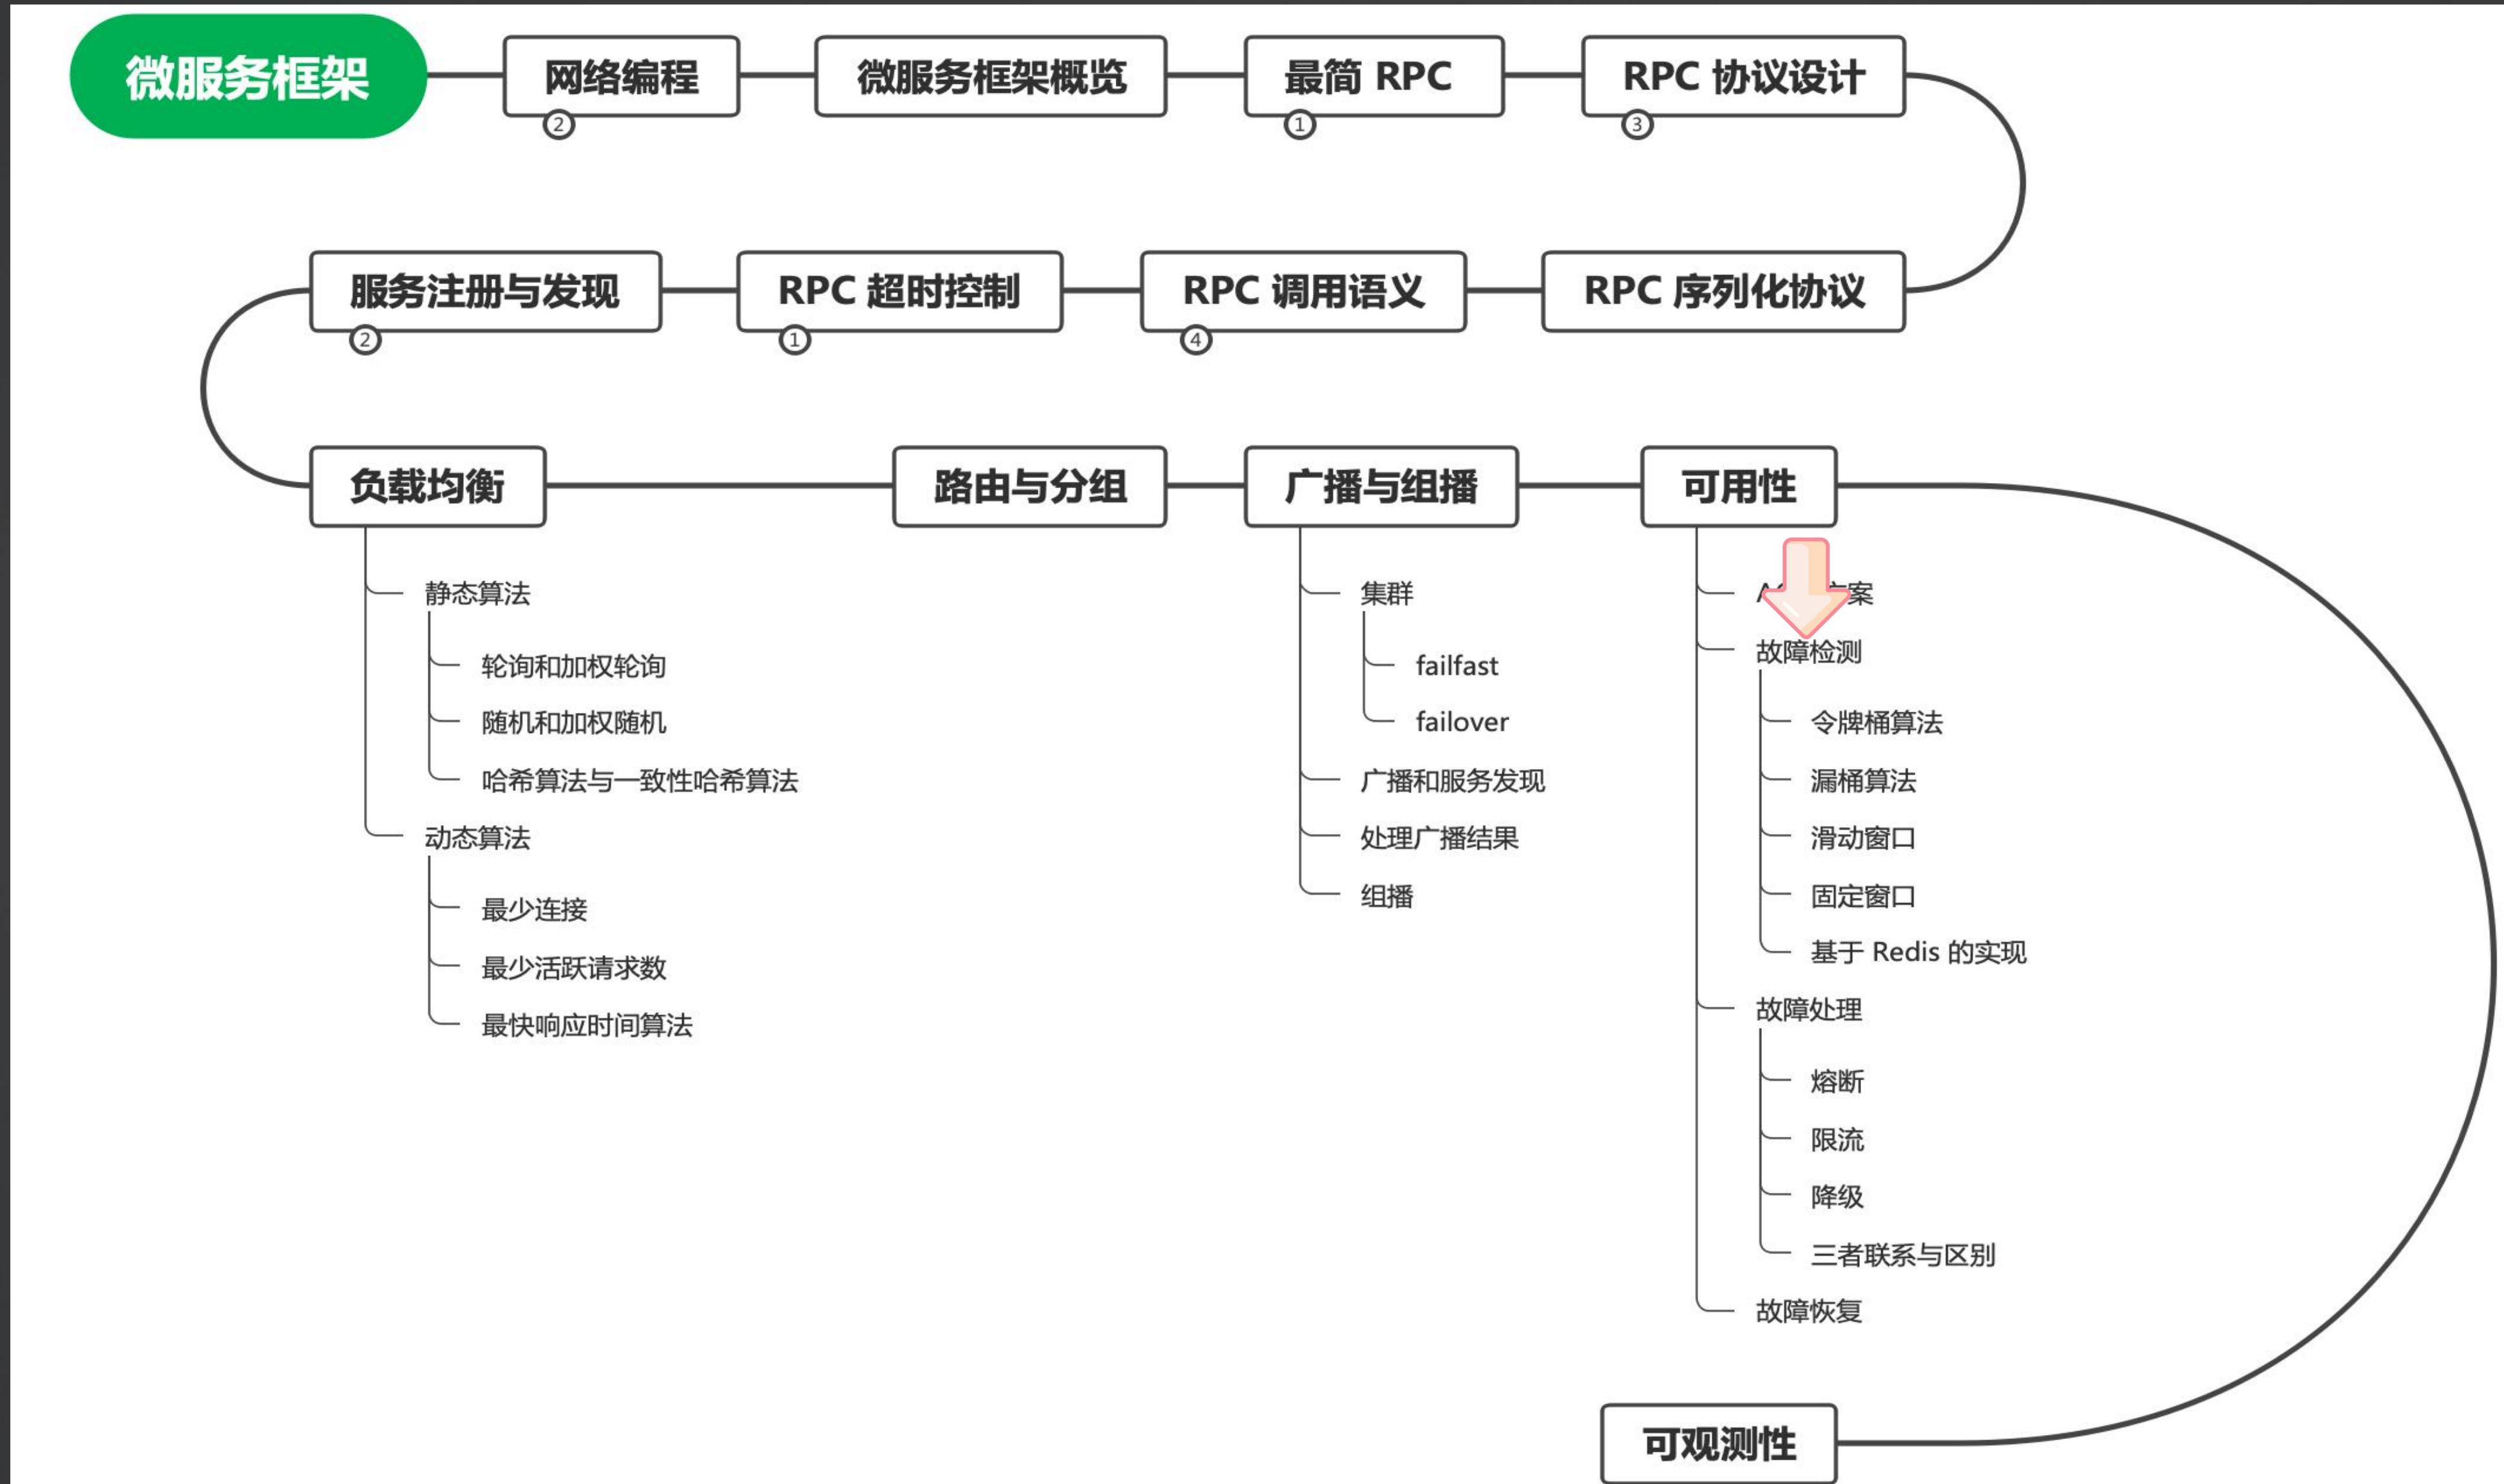
go-micro 的熔断，默认的实现是支持了本地以及基于 hystrix 两种。其中 gobreaker 利用的是 github.com/sony/breaker 的实现。



```
c.mu.Lock()
cb, ok := c.cbs[svc]
if !ok {
    cb = gobreaker.NewTwoStepCircuitBreaker(c.bs)
    c.cbs[svc] = cb
}
c.mu.Unlock()

cbAllow, err := cb.Allow() 几乎和限流设计一样
if err != nil {
    return errors.New(req.Service(), err.Error(), code)
}

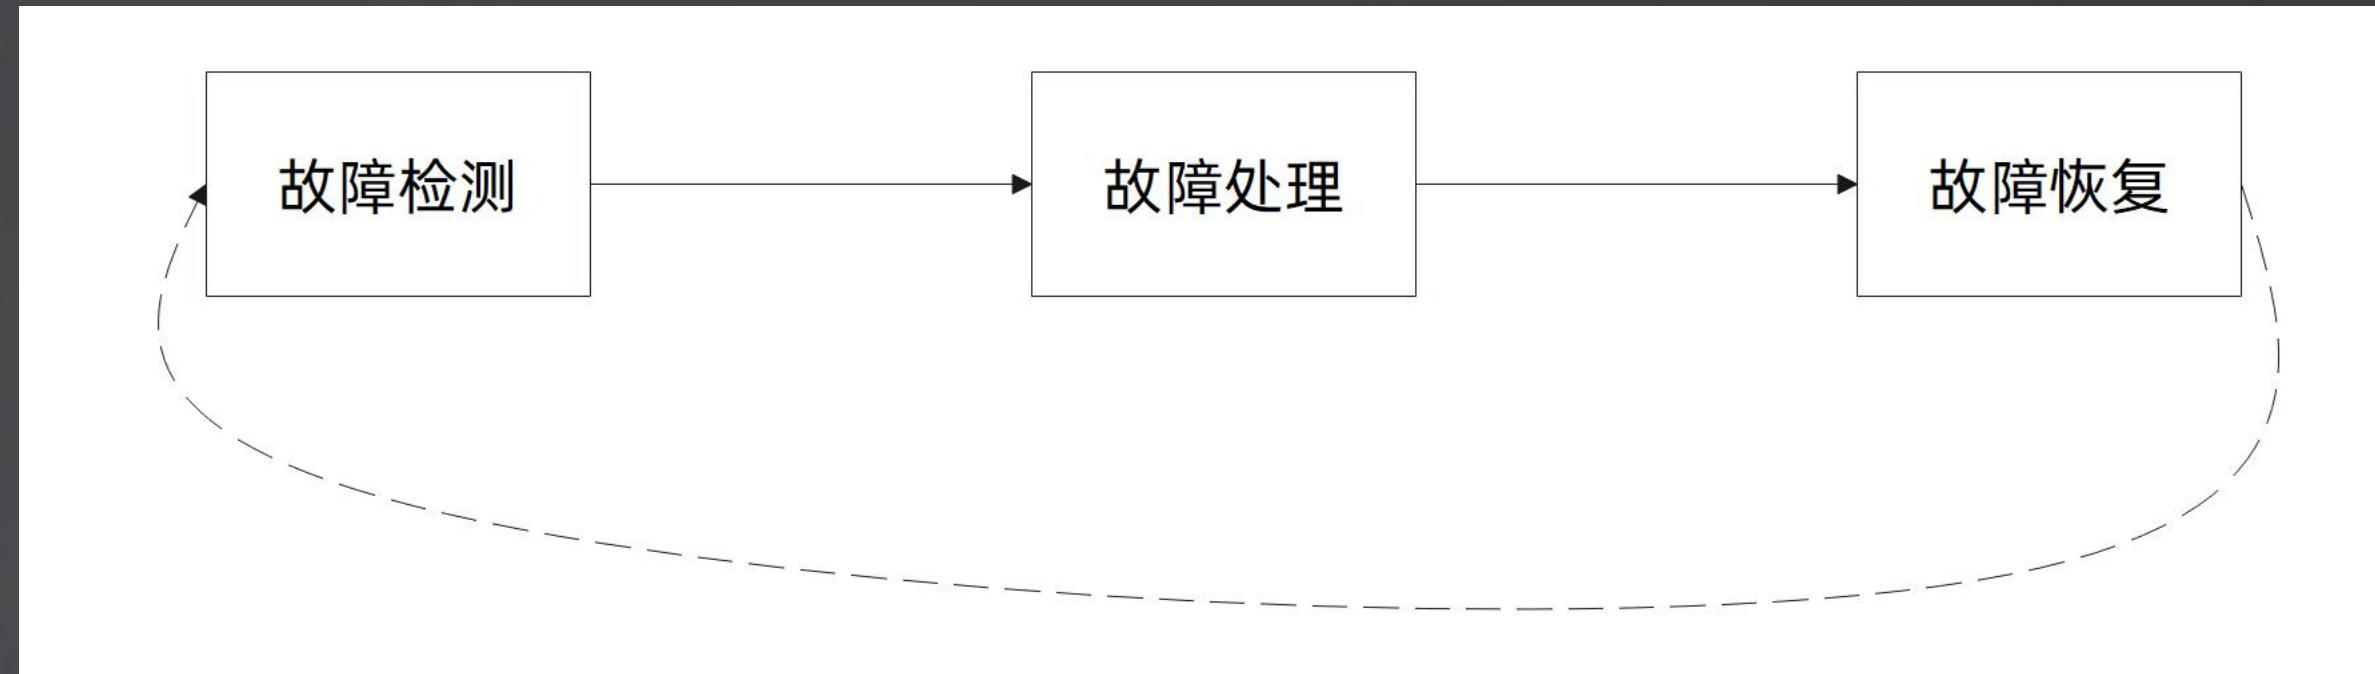
if err = c.Client.Call(ctx, req, rsp, opts...); err ==
    cbAllow(success: true)
    return nil
```



可用性：熔断、限流、降级

熔断、限流和降级并没有本质区别，都可以归属到故障处理的范畴里面：

- 故障检测：使用一些特定的算法，判定服务是否处于不健康状态。
- 故障处理
 - 限流：一段时间内只允许特定数量的请求被处理。
 - 熔断：全部请求都会被拒绝。
 - 降级：全部请求都会执行一段更加简单的逻辑。
- 故障恢复：即如果服务被判定为处于异常状态之后，什么时候再恢复过来。



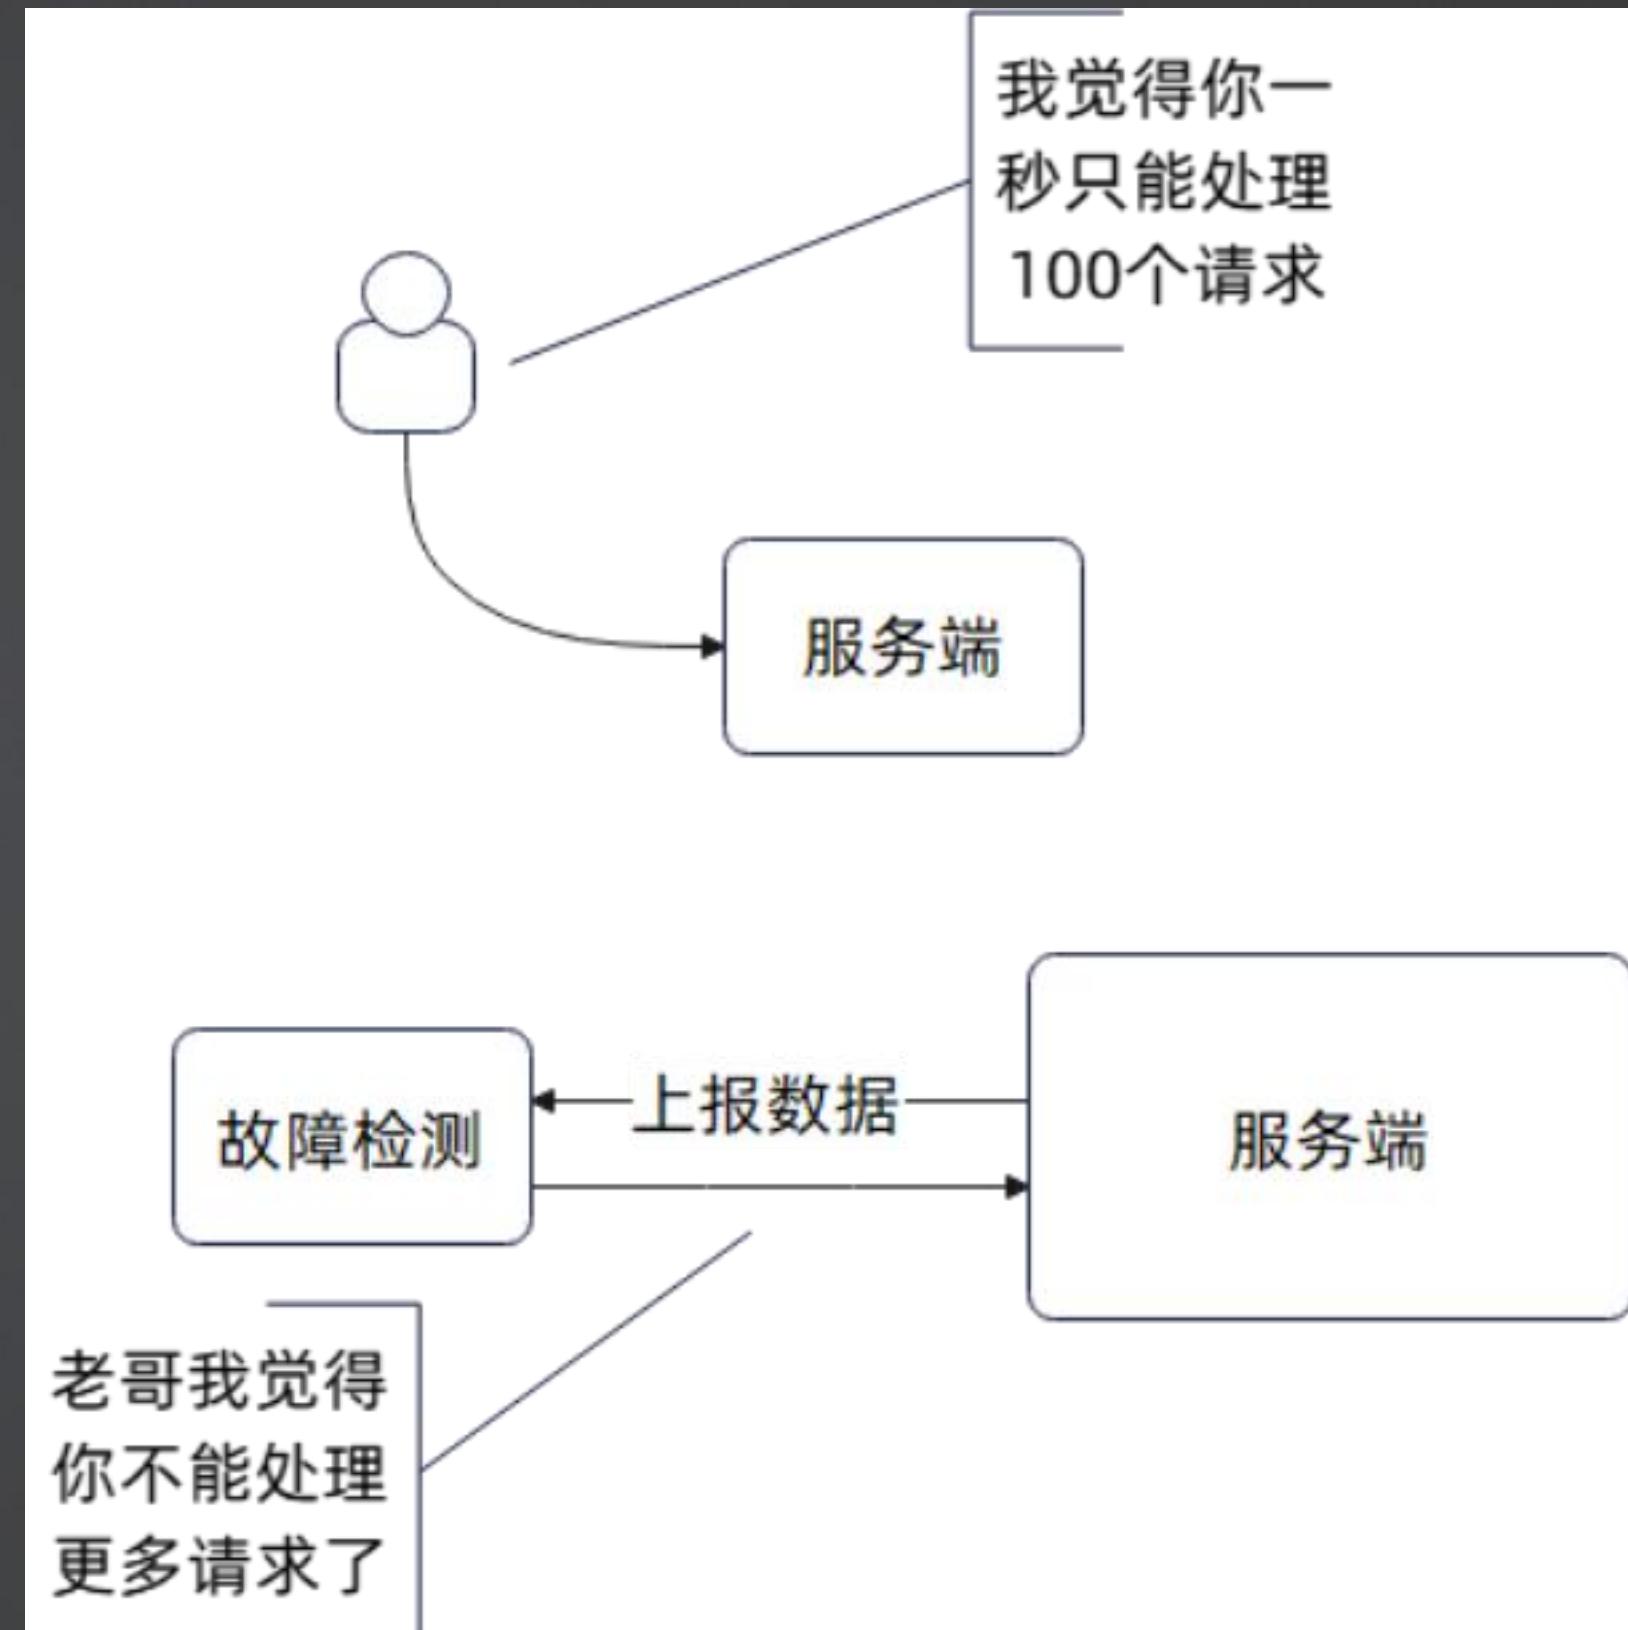
对于一个服务来说，它就是在这几个状态中不断变迁。

可用性：故障检测

从故障检测算法的类型来看，可以分成：

- **静态类型的算法**：例如限流算法设置为一秒内只能执行一百个请求，这一类就是静态的，依赖于测试或者程序员根据个人经验提前设置好。**令牌桶、漏桶、固定窗口和滑动窗口**都属于这一类。
- **动态类型的算法**：根据服务当前状态动态判断，例如根据错误率、响应时间，或者典型的 BBR 算法。

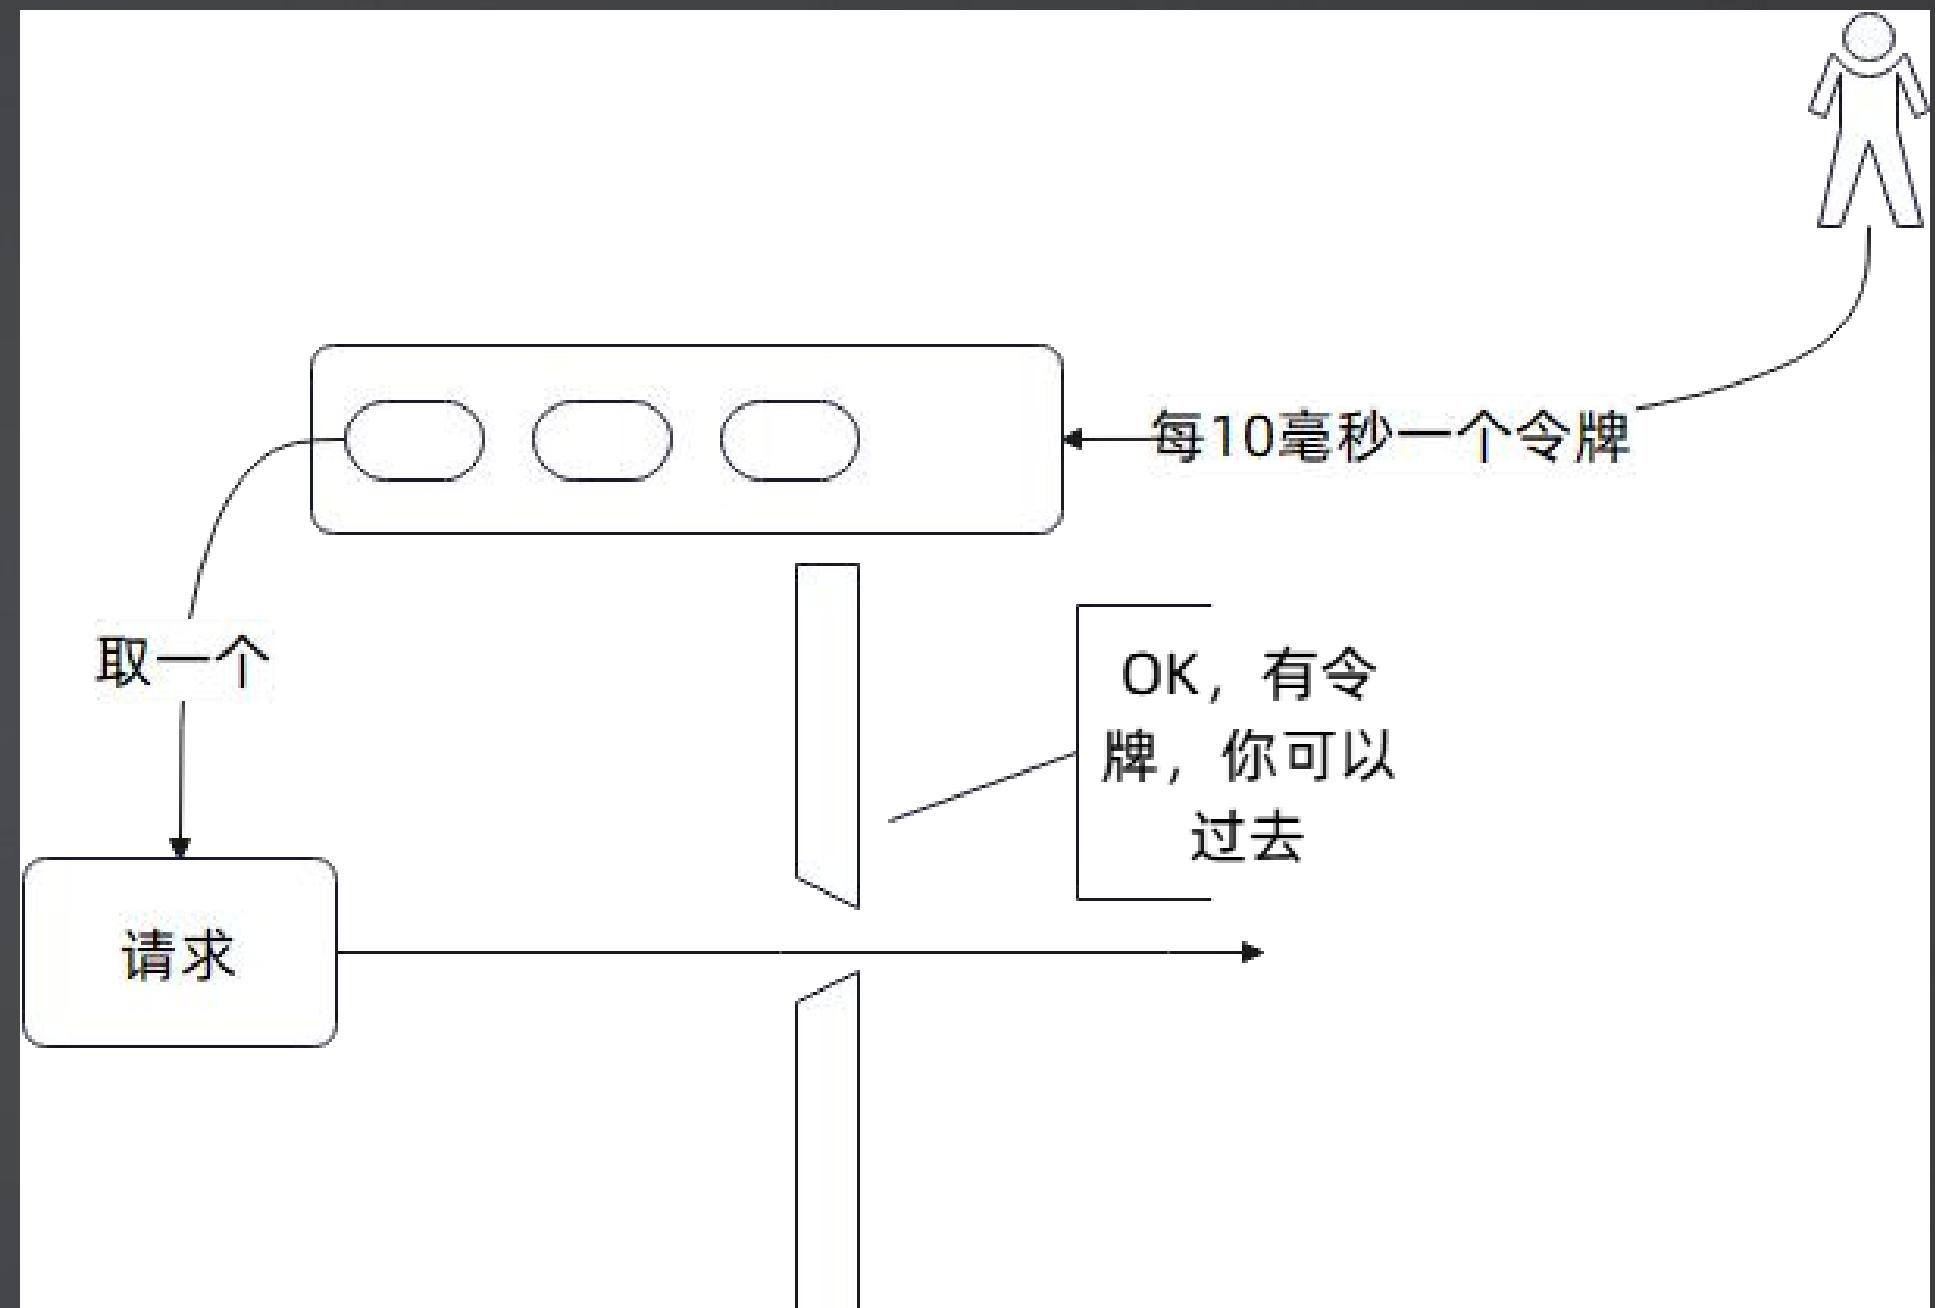
对于绝大多数应用来说，静态类型算法就足够了。



限流算法：令牌桶

令牌桶算法要点：

- 有一个人按一定的速率发令牌
- 令牌会被放到一个桶里
- 每一个请求从桶里面拿一个令牌
- 拿到令牌的请求就会被处理
- 没有拿到令牌的请求就会：
 - 直接被拒绝
 - 阻塞直到拿到令牌或者超时



限流算法：令牌桶

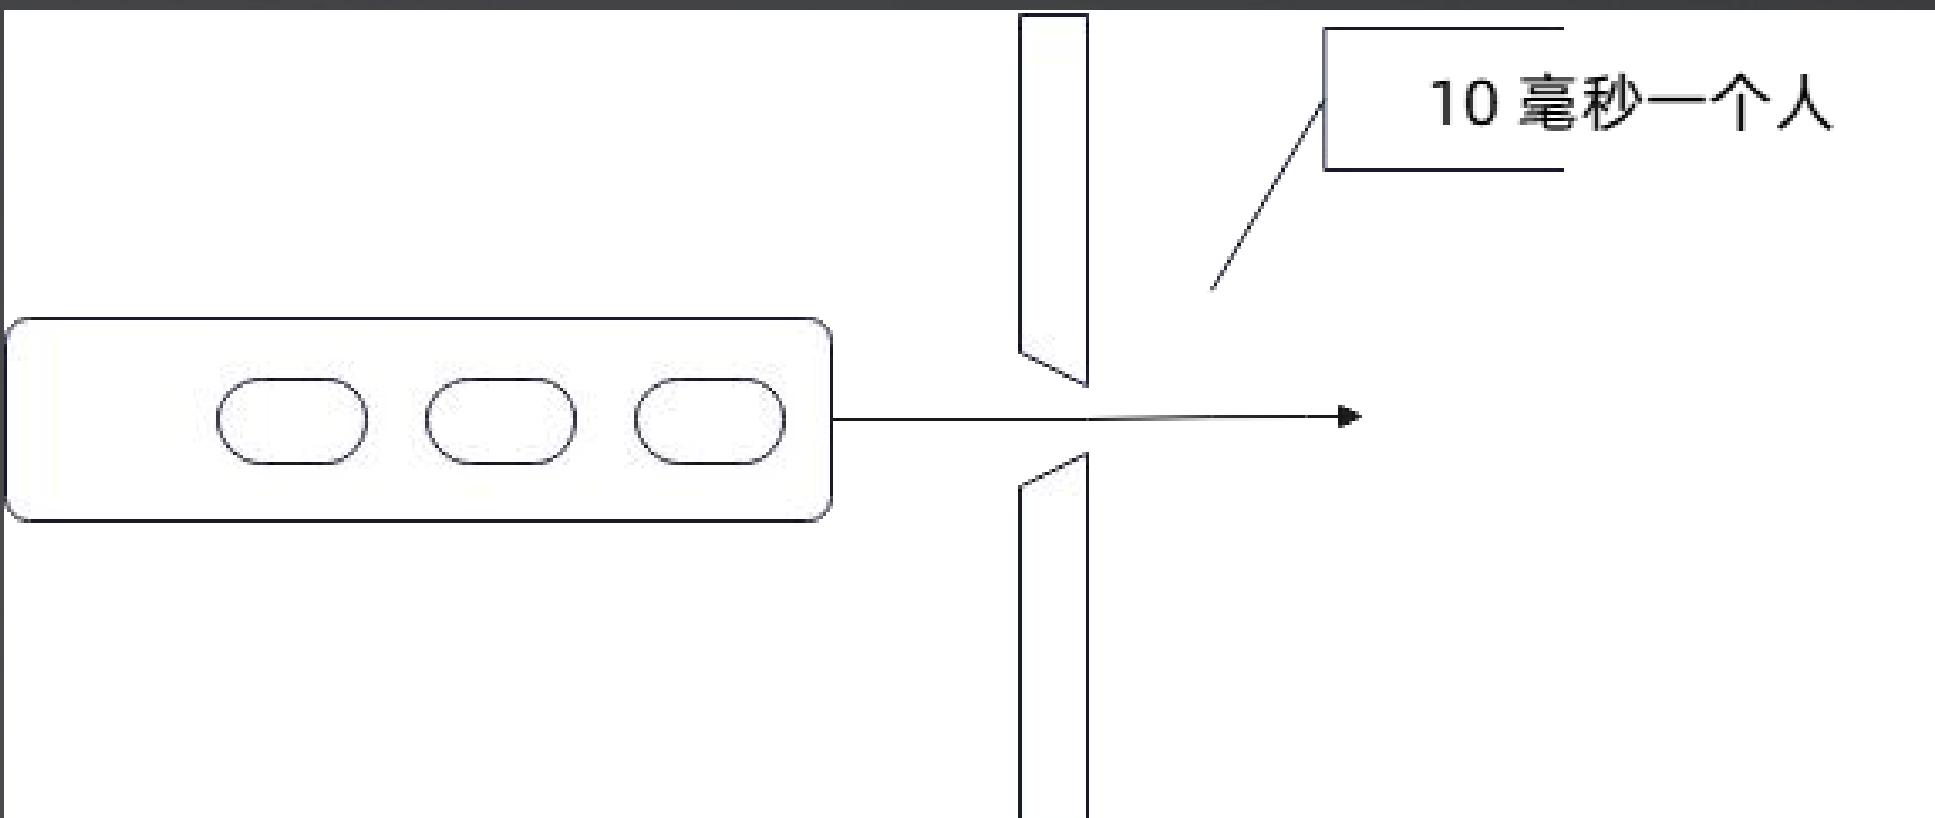
```
go func() {
    producer := time.NewTicker(interval)
    defer producer.Stop()
    for {
        select {
        case <-res.close:
            // 关闭
            return
        case <-producer.C:
            select {
            //case <- res.close:
            // 关闭。在这里其实可以没有这个分支
            //return
            case res.tokens <- struct{}{}:
            default:
                // 加 default 分支防止一直没有人取令牌，我们这
            }
        }
    }
}
```

```
return func(ctx context.Context, req interface{}, int
    select {
    case <-ctx.Done():
        return resp: nil, ctx.Err()
    case <-l.close:
        // 已经关闭了
        // 这里你可以决策，如果认为限流器被关了，就代表不用限
        // 这种情况下，还要考虑提供 Start 方法重启限流器
        // 我这里采用另外一种语义，就是我认为限流器被关了，其
        return resp: nil, errors.New(text: "micro: 系统
    case <-l.tokens:
        return handler(ctx, req)
    }
}
```

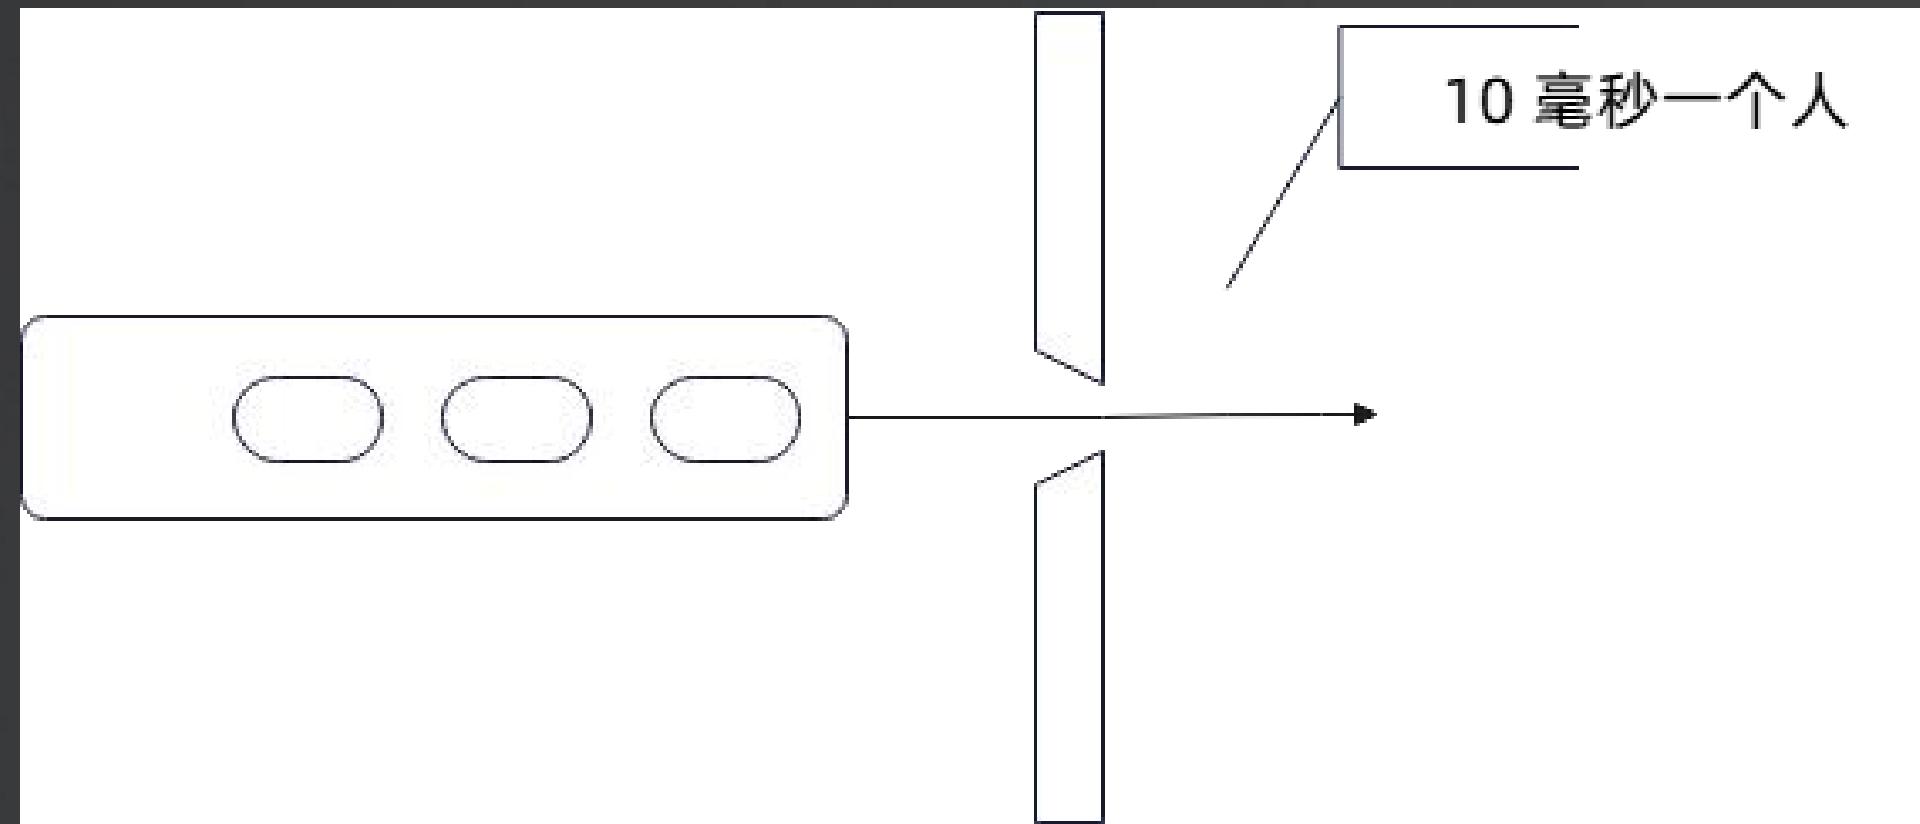
限流算法：漏桶

漏桶算法要点：

- 请求过来先排队
- 每隔一段时间，放过去一个请求
- 请求排队直到通过，或者超时



限流算法：漏桶



```
func (l *LeakyBucketLimiter) LimitUnary() grpc.UnaryS  
    return func(ctx context.Context, req interface{},  
        select {  
            case <-ctx.Done():  
                // 等令牌过期了  
                return resp:nil, ctx.Err()  
            case <-l.producer.C:  
                return handler(ctx, req)  
        }  
    }  
}
```

限流算法：漏桶与令牌桶

漏桶算法要点：

- 请求过来先排队
- 每隔一段时间，放过去一个请求
- 请求排队直到通过，或者超时

令牌桶算法要点：

- 有一个人按找一定的速率发令牌
- 令牌会被放到一个桶里，这个桶只能放固定数量的令牌
- 每一个请求从桶里面拿一个令牌
- 拿到令牌的请求就会被处理
- 没有拿到令牌的请求就会：
 - 直接被拒绝
 - 阻塞直到拿到令牌或者超时

两者效果是一样的。

限流算法：固定窗口

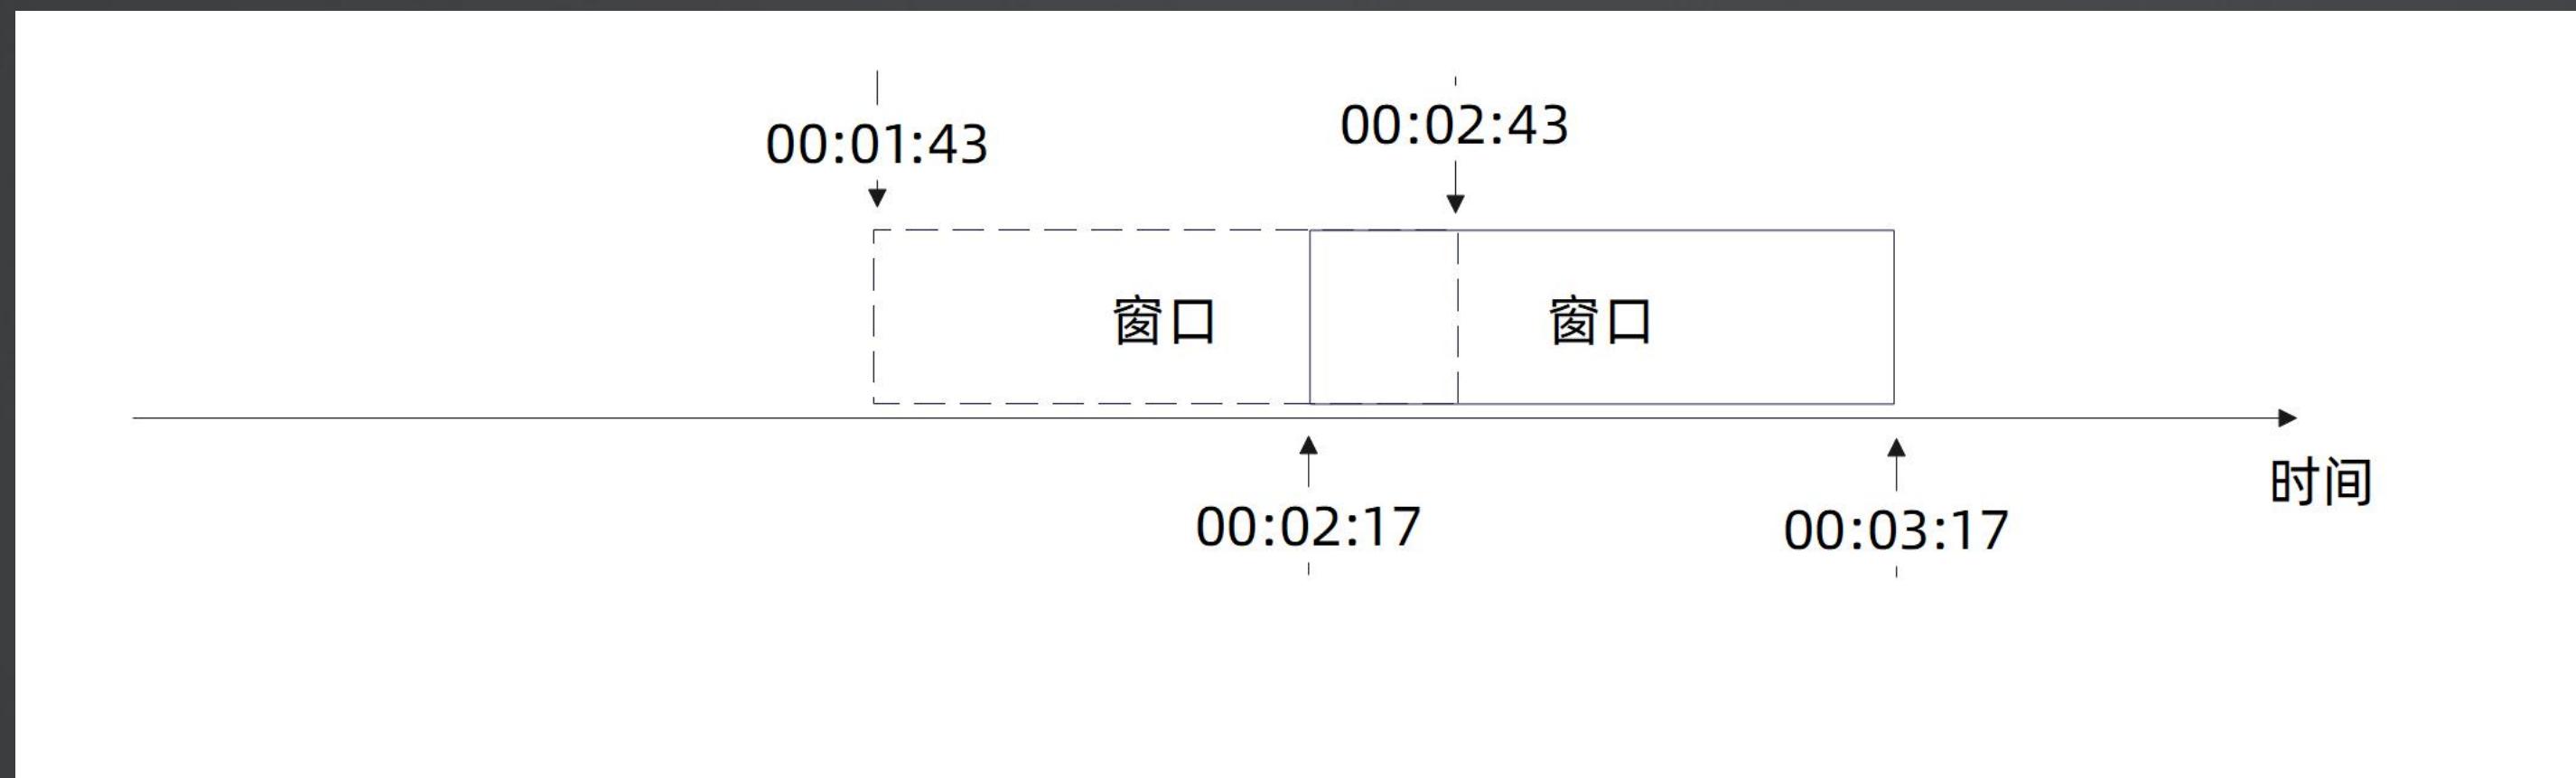


限流算法：固定窗口

```
nc (t *FixWindowLimiter) BuildServerInterceptor() grpc.UnaryServerInterceptor
    return func(ctx context.Context, req interface{}, info *grpc.UnaryServerInfo, handler grpc.UnaryHandler) (resp interface{}, err error) {
        // 考虑 t.cnt 重置的问题
        current := time.Now().UnixNano()
        timestamp := atomic.LoadInt64(&t.timestamp)
        cnt := atomic.LoadInt64(&t.cnt)
        if timestamp + t.interval < current {
            // 这意味着这是一个新窗口
            // 重置窗口
            if atomic.CompareAndSwapInt64(&t.timestamp, timestamp, current) {
                //atomic.StoreInt64(&t.cnt, 0)
                atomic.CompareAndSwapInt64(&t.cnt, cnt, new: 0)
            }
        }
        cnt = atomic.AddInt64(&t.cnt, delta: 1)
        if cnt > t.rate {
            err = errors.New(text: "触发瓶颈了")
            return
        }
        resp, err = handler(ctx, req)
        return
    }
}
```

限流算法：滑动窗口

从当前时间开始，往前回溯一段时间，只能处理一定数量的请求。



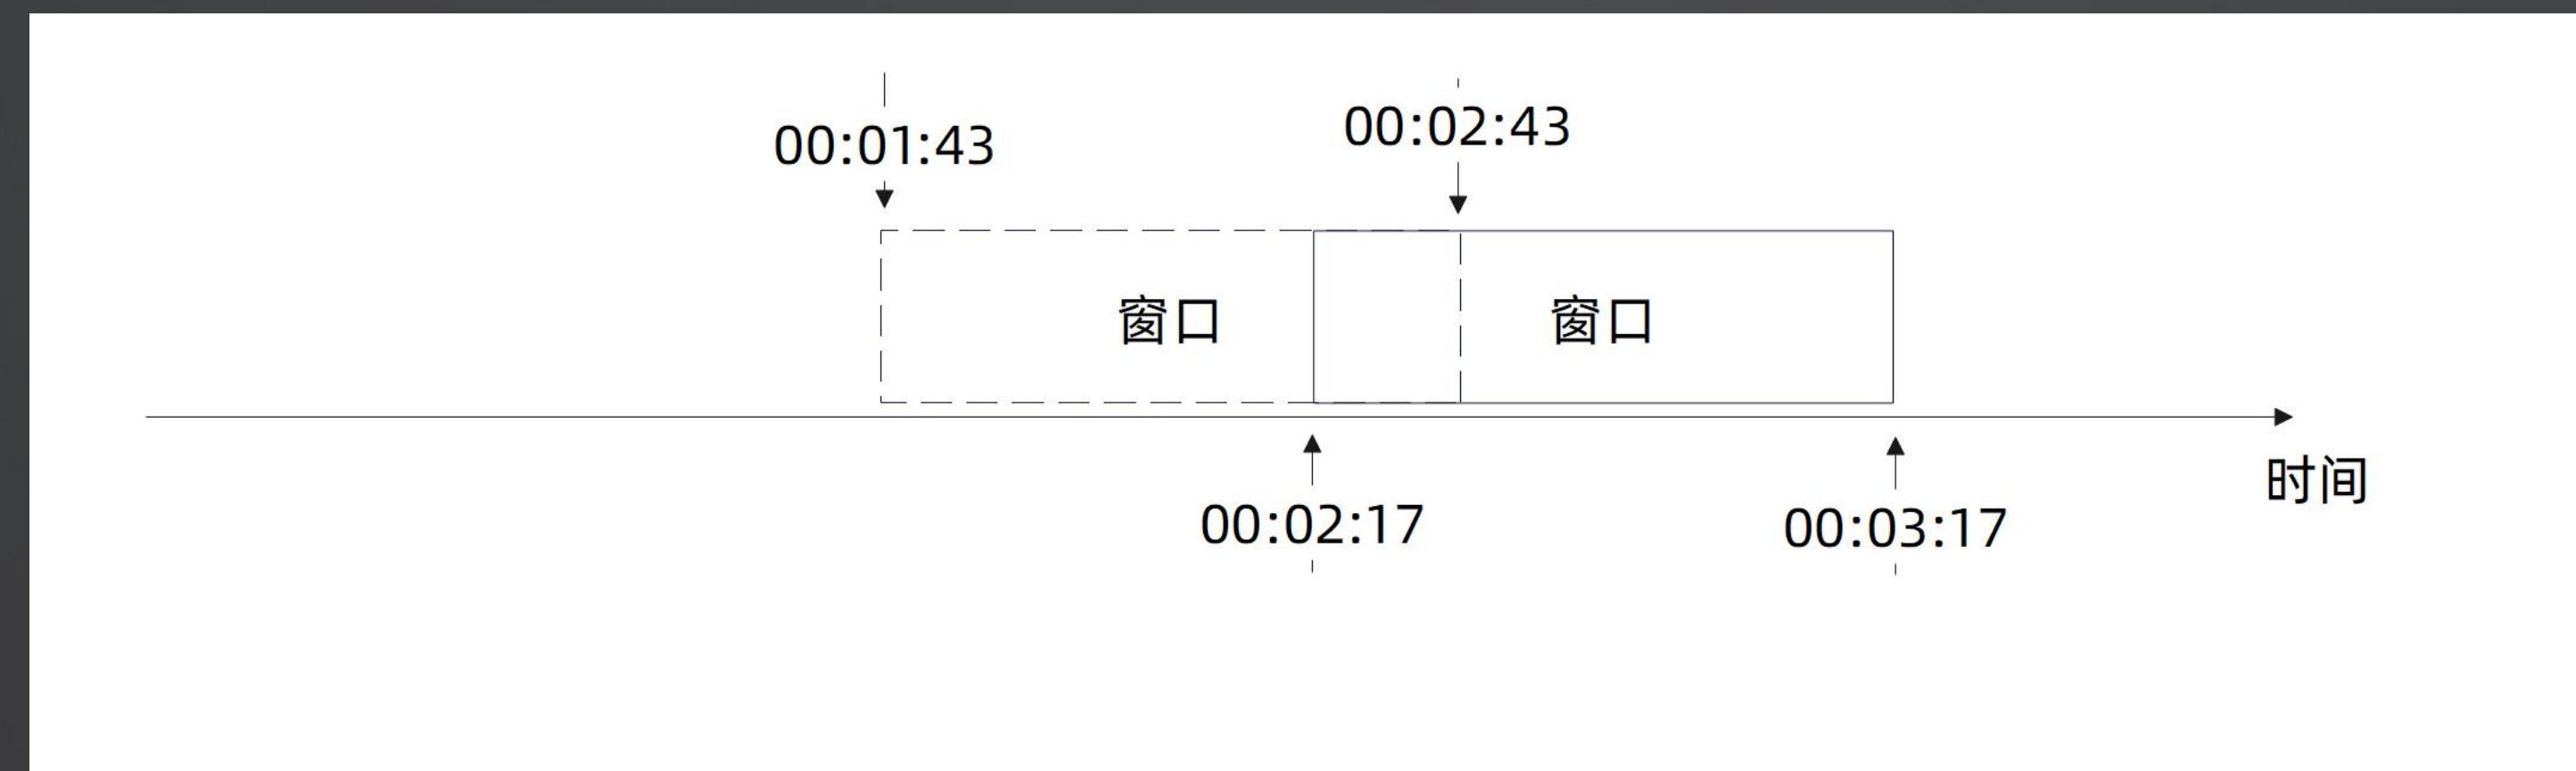
滑动窗口的核心是：这个窗口永远是以当前时间截为准，往前回溯。例如当前时间点是 00:03:17，往前回溯一分钟，就是一个一分钟长度的窗口。

限流算法：滑动窗口

```
func (l *SlideWindowLimiter) limit() bool {
    l.mutex.Lock()
    defer l.mutex.Unlock()
    // 快路径
    size := l.queue.Len()
    current := time.Now().UnixNano()
    if size < l.rate {
        l.queue.PushBack(current)
        return false
    }
    // 慢路径
```

```
// 慢路径
boundary := current - l.interval
timestamp := l.queue.Front()
// 删除已经不在窗口内的元素
for timestamp != nil && timestamp.Value.(int64) < boundary {
    l.queue.Remove(timestamp)
    timestamp = l.queue.Front()
}
if l.queue.Len() < l.rate {
    l.queue.PushBack(current)
    return false
}
return true
```

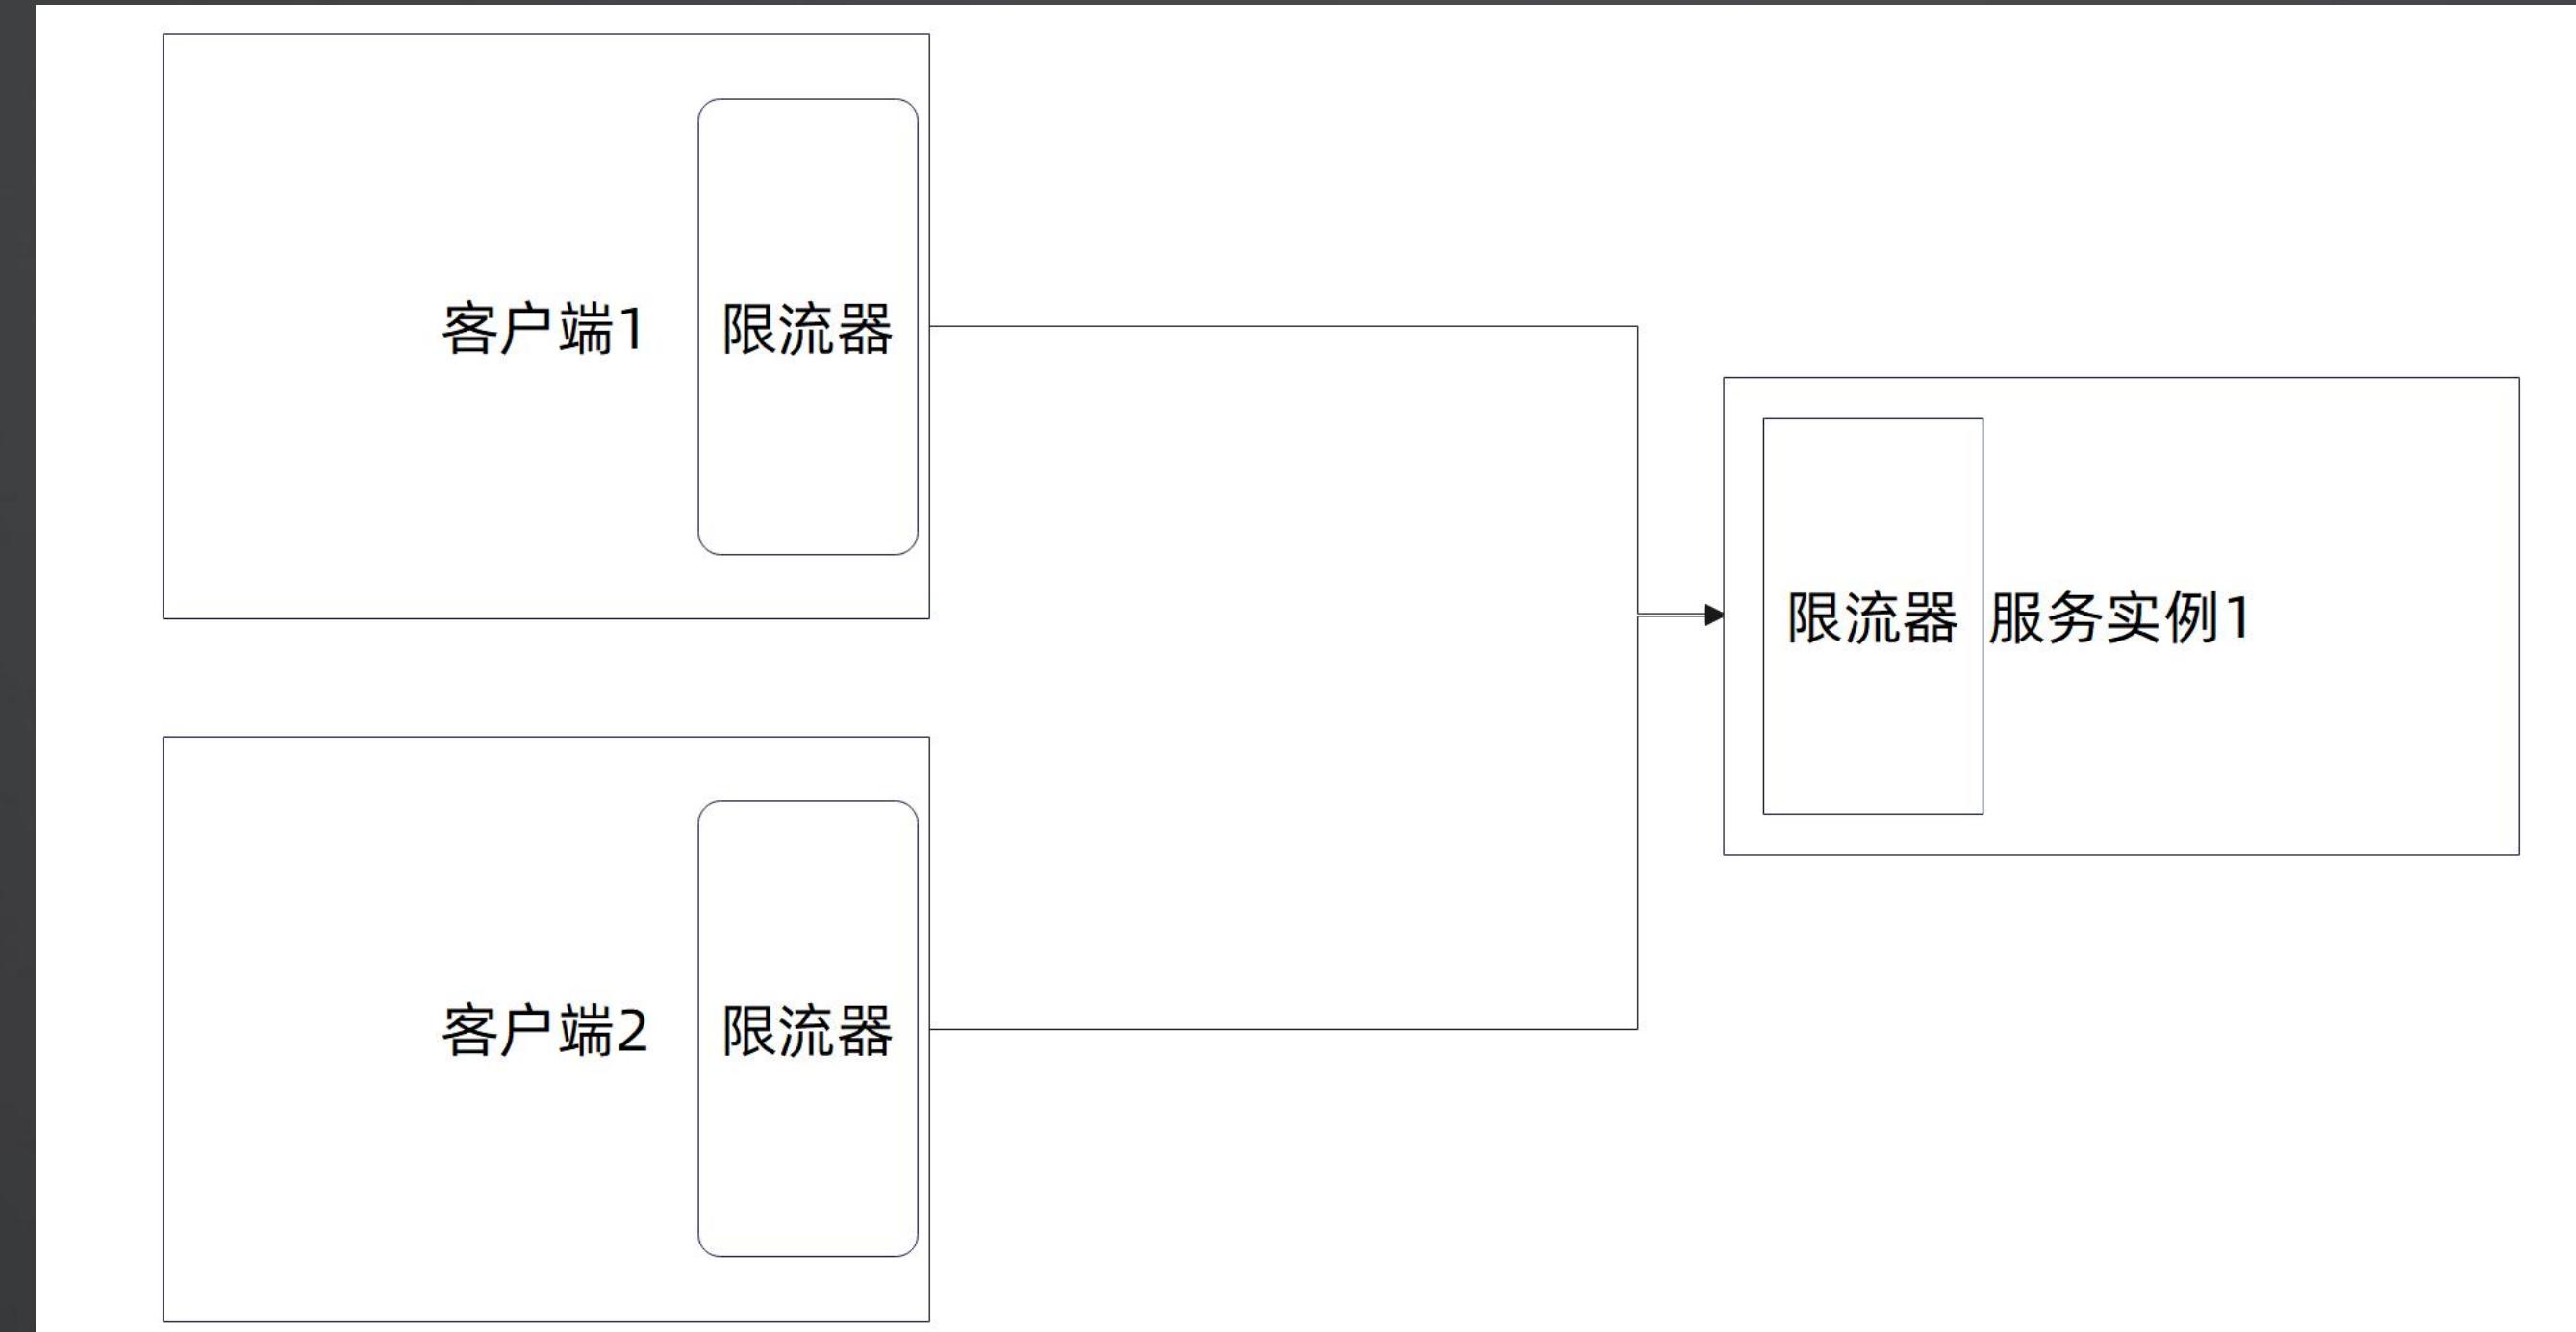
限流算法：两种窗口对比

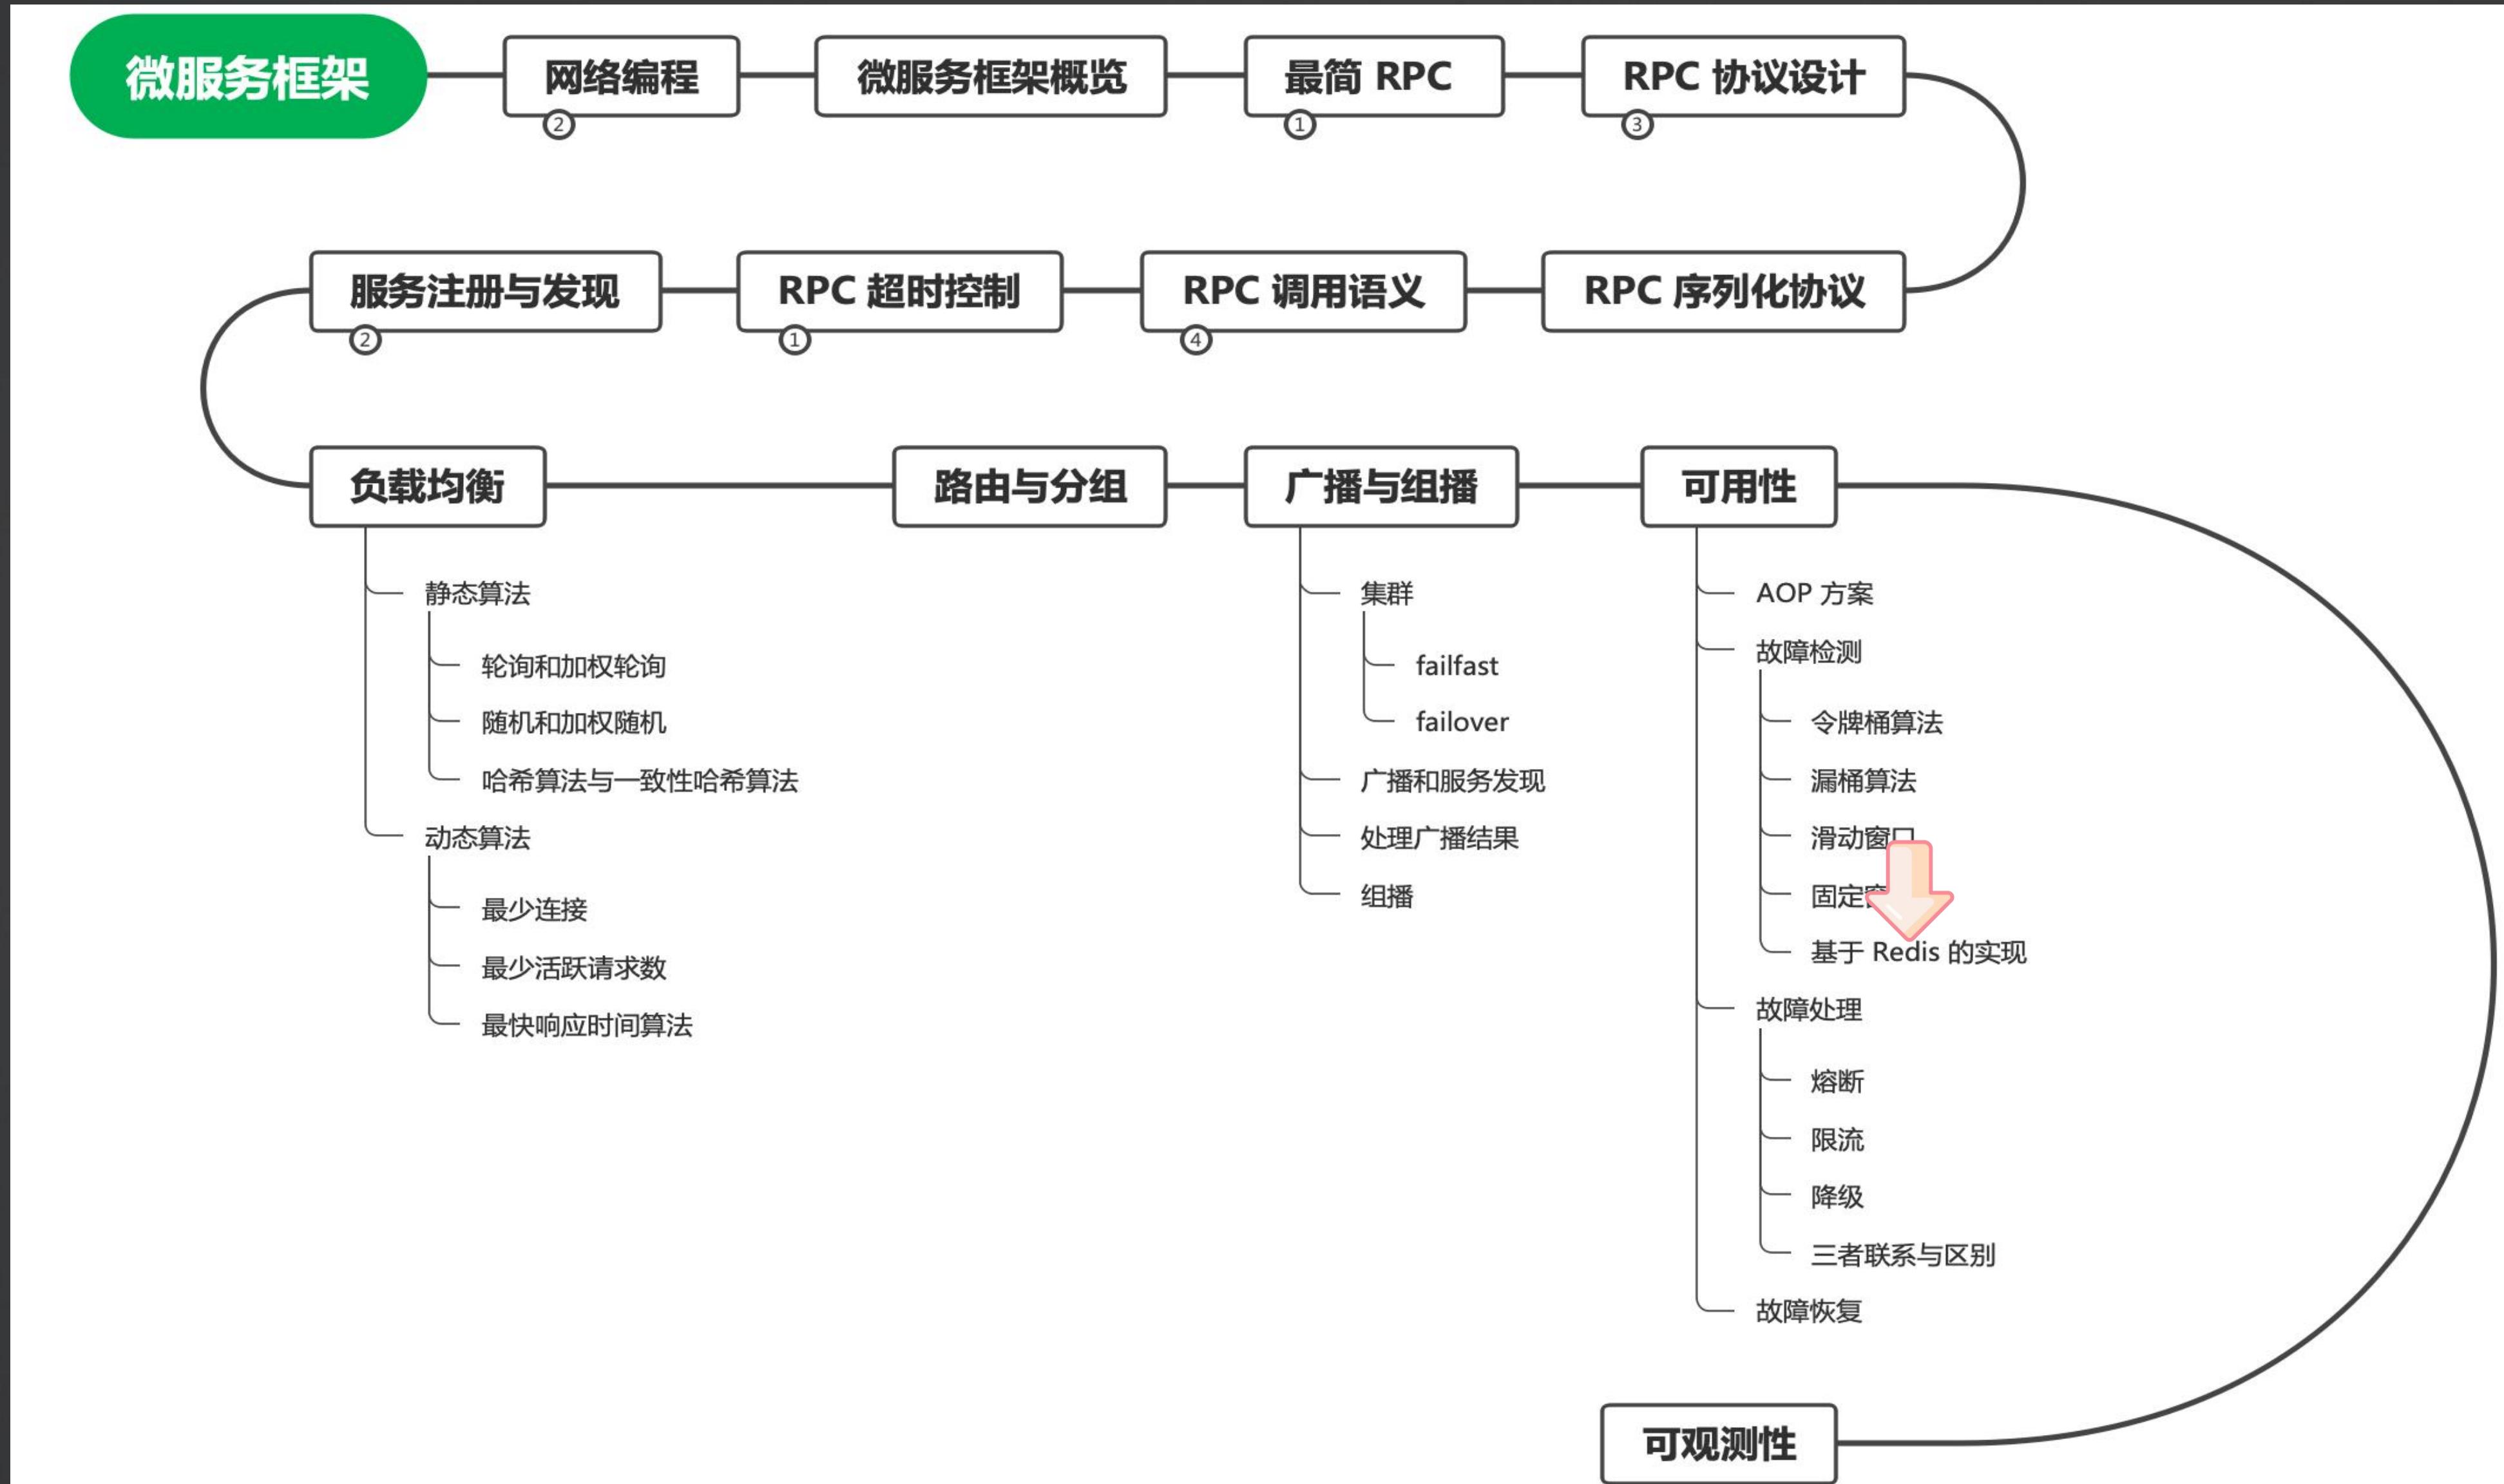


客户端限流与服务端限流

前面代码演示的都是服务端限流——利用的是 gRPC 的服务端拦截器。

从理论上来说，还可以考虑客户端限流。客户端限流用得少，主要是因为很可能不同客户端上单独限流了，结果合在一起却超过了服务器处理能力。



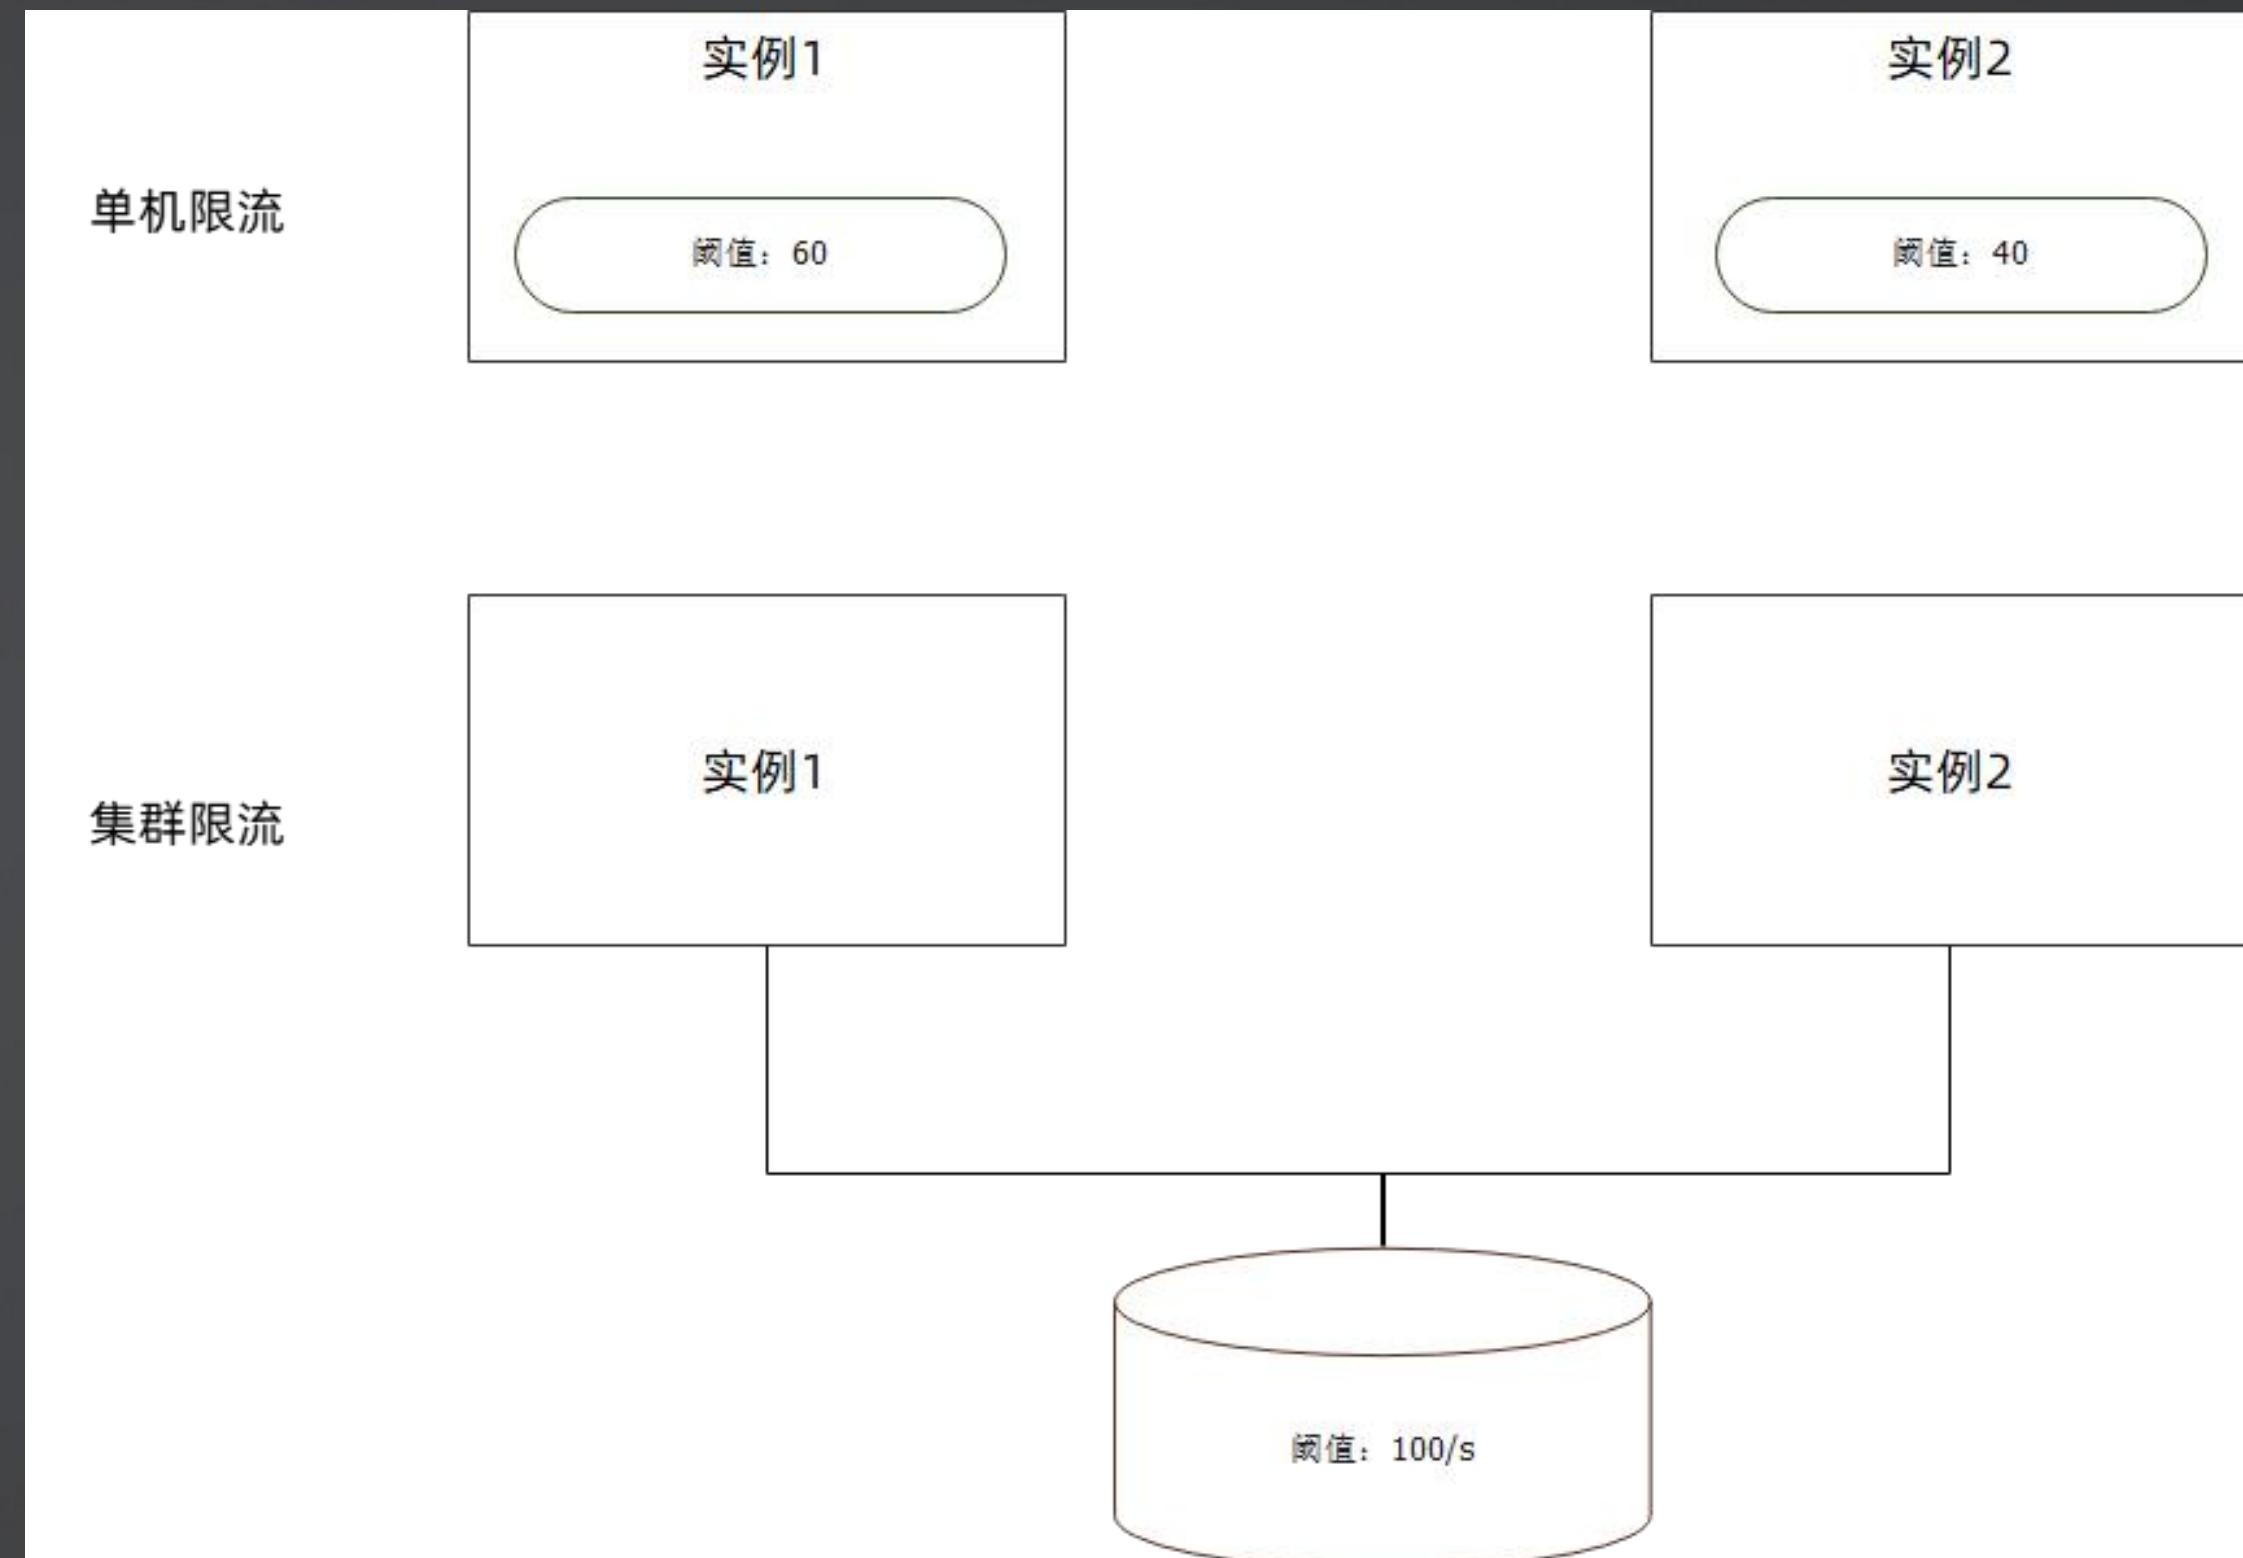


单机限流与集群限流

前面我们讨论的都是单机限流，在微服务框架下我们还可以考虑对集群进行限流。

集群限流特征：

- 非常接近网关限流。
- 集群限流主要依赖于在不同的实例之间同步阈值、当前请求数，目前使用 Redis 的比较多（高并发）。



基于 Redis 的实现：固定窗口

```
local val = redis.call('get', KEYS[1])
local limit = tonumber(ARGV[2])
if val == false then
    if limit < 1 then
        -- 执行限流
        return "true"
    else
        -- key 不存在，设置初始值 1，并且设置过期时间
        redis.call('set', KEYS[1], 1, 'PX', ARGV[1])
        -- 不执行限流
        return "false"
    end
elseif tonumber(val) < limit then
    -- 自增 1
    redis.call('incr', KEYS[1])
    -- 不需要限流
    return "false"
else
    -- 限流
    return "true"
end
```

基于 Redis 的实现：滑动窗口

```
-- 先挪动窗口
redis.call('ZREMRANGEBYSCORE', key, '-inf', min)

-- 看看还有没有容量
local cnt = redis.call('ZCOUNT', key, '-inf', '+inf')

if cnt >= threshold then
    -- 限流
    return "true"
else
    -- 值和优先级我们都设置成当前时间戳
    redis.call('ZADD', key, now, now)
    -- 这里设不设置过期时间影响不大，设置了过期时间可以防止长期没有
    redis.call('PEXPIRE', key, window)
    -- 不限流
    return "false"
end
```

本质上，可以理解为我们把刚才的算法用 lua 脚本再写了一遍。

限流总结

限流对象，即针对什么限流，除了前面的单机限流和集群限流，还有：

- 接口维度限流
- 方法维度限流
- 业务相关限流：
 - 例如针对用户限流。
 - 针对 IP 限流：常见的针对登录请求，同一个 IP 不能频繁登录。

业务相关一般针对安全、业务价值。大体上的逻辑就是牺牲不重要的来保护重要的。

限流也可以考虑跨服务限流，即如果服务很重要，那么可以将不重要的服务流量摘掉，或者丢弃一部分，腾出资源来保护核心服务。

拒绝策略

在我们的课堂里面，目前所有的限流都默认返回了错误，在实际中我们可以考虑：

- 标记一下这个请求是限流请求，后续业务走简易路径。例如结合我们前面讲的缓存模式，这种被标记的请求，我们在缓存未命中的时候就直接返回，不会再对数据库里面加载。
- 直接返回一个固定的响应：和上一种措施比起来，这种直接在拦截器里面就返回了。
- 缓存请求：前面我们的令牌桶和漏桶阻塞住了，在某种程度上也可以看做是缓存。这里面的缓存是指我们将请求丢到一个数据库或者 Redis 之类的地方存好，后面再拿出来重做。
- 转为异步模式：拦截器将请求标记为限流请求。那么后面的业务就会直接返回一个类似 202 的响应，即请求已经接收。后续再由一个调度器重新调度它来真正执行。和前者比起来，它不是由拦截器来缓存请求。
- 转发到别的服务器：这种设计更加罕见，也就是限流的请求，可以被转发到别的机器上，但是对于微服务框架来说，这意味着在服务端也要像客户端那样发现服务实例，并且判定服务实例的性能。一种简化设计就是结合前面的 failover，返回一个类似于 302 重定向的错误，让客户端重新发请求到别的节点。

拒绝策略：简易路径

后续的中间件可以检测这种标记位。我们只需要在前面触发限流的时候设置这个标记位就可以。

在业务中，你们要仔细甄别这一类的场景，在面试的时候你们则可以说：

- 业务分成了快路径和慢路径两种，其中慢路径很消耗资源。
- 在没有触发限流的时候，先走快路径，不行则走慢路径。
- 在触发限流的时候，则是只走快路径。

```
var markLimitedRejection rejectStrategy = func(ctx context.Context, info interface{}, req interface{}, handler grpc.UnaryHandler) (interface{}, error) {
    ctx = context.WithValue(ctx, key: "limiter", val: true)
    return handler(ctx, req)
}

func (r *RateLimitReadThroughCache) Get(ctx context.Context, key string) (val, error) {
    val, err := r.Cache.Get(ctx, key)
    if err == KeyNotFound && ctx.Value(key: "limited") == nil {
        val, err = r.LoadFunc(ctx, key)
        if err == nil {
            if err := r.Set(ctx, key, val, time.Minute); err != nil {
                log.Fatalf(format: "刷新缓存失败, err: %v", err)
            }
        }
    }
    return val, err
}
```

总结：限流、熔断和降级究竟有啥区别？

实际上，它们的区别很少：

- 如果判断到资源不足，只允许一部分请求被正常处理，那么就是限流。而对于那些没有被正常处理的请求来说：
 - 如果请求被直接拒绝，返回错误，那么这部分请求就是被熔断了。
 - 如果请求没有被拒绝，但是返回了默认值，或者走了简易路径，那么就是降级了。
- 从接口设计的角度来说，它们也非常接近，例如定义一个 Allow 就可以了。
- 算法层面上它们也都是通用的。

面试要点

首先要熟练掌握各种限流算法，不仅仅是原理上的，也要能够写出来代码。

- 限流的几个算法？
- 滑动窗口和固定窗口的区别？固定窗口和滑动窗口比起来，滑动窗口的限流更加平滑，因为窗口是在持续移动的。
- 令牌桶和漏桶的区别？
- 什么是降级？其实就是在业务层面上准备快慢两条路径。不降级的时候执行的是慢路径，一般来说它就是正常执行业务逻辑；快路径可以是直接返回默认值，也可以是存储一下数据，后面异步处理。
- 什么是熔断？就是在系统故障（或者快要故障）的时候，拒绝新的请求。这里要注意，如果不是拒绝新的请求，也可以说是降级了。
- 什么是限流？在一定的时间段内，只允许一部分请求被处理，其余请求被拒绝。实际上也可以考虑返回默认值之类的，也就是接近降级的策略。
- 触发降级和熔断之后，怎么恢复过来？常见的做法都是过一段时间之后直接退出降级和熔断状态；高级一点的做法是退出之前先试探一下，放过去少部分请求。
- 熔断、限流和降级三者之间的联系、区别？注意我们课堂上的说法，三者之间其实并不是泾渭分明的，本质上只是处理策略上稍微有点区别。
- 可以针对什么来限流？单机限流、集群限流、业务限流（用户限流、IP 限流）。

Q & A

THANKS